

## Método do gradiente espectral

(1)

Quase-Newton:  $x^{k+1} = x^k - B_k^{-1} \nabla f(x^k)$ ,

$B_{k+1} S_k = y_k$  (equação secante), onde

$S_k = x^{k+1} - x^k$  e  $y_k = \nabla f(x^{k+1}) - \nabla f(x^k)$ .

Escolha simples:  $B_{k+1} = \sigma_{k+1} I$ ,  $\sigma_{k+1} > 0$ .

Esta escolha não satisfaz a equação secante em geral, mas podemos procurar o  $\sigma_{k+1}$  que

melhor aproxima a equação secante

(2

" $(\sigma \pm) s_k = y_k$ " no seguinte sentido:

$$\min_{\sigma} \frac{1}{2} \|\sigma s_k - y_k\|^2$$

Este problema é convexo e pode ser resolvido anulando a derivada da função objetivo:

$$0 = \frac{d}{d\sigma} \left( \frac{1}{2} \|\sigma s_k - y_k\|^2 \right) = (\sigma s_k - y_k)^t s_k$$

$$\Rightarrow \boxed{\sigma_{k+1} = \frac{s_k^t y_k}{s_k^t s_k}} \quad (\text{sempre que } s_k \neq 0)$$

Seendo  $B_{k+1} = \sigma_{k+1} I$ , temos  $B_{k+1}^{-1} = \frac{1}{\sigma_{k+1}} I$ . [3]

Agregando busca linear, temos a iteração

$$x^{k+1} = x^k - t_k \lambda_k \nabla f(x^k), \quad \lambda_k = \frac{1}{\sigma_k} = \frac{s_{k-1}^t s_{k-1}}{s_{k-1}^t y_{k-1}}$$

(desde que  $s_{k-1}^t y_{k-1} > 0$ ),

com passo  $t_k > 0$ . Esta é a iteração do método do gradiente espectral.

Observe que se trata de uma espécie de "gradiente escalado", com direção  $d^k = -\lambda_k \nabla f(x^k)$ .

## Sobre o cálculo do passo espectral $\lambda_k$

(4)

1) Assim como nos métodos quase-Newton, o primeiro passo  $\lambda_0$  deve ser fornecido (lembre-se que  $B_0 = \frac{1}{\lambda_0} I$  é dada pelo usuário). Uma escolha que funciona bem é

$$\lambda_0 = \min \left\{ \lambda_{\max}, \max \left\{ \lambda_{\min}, \frac{1}{\|\nabla f(x^0)\|_{\infty}} \right\} \right\},$$

onde  $0 < \lambda_{\min} < \lambda_{\max}$  são parâmetros.

Note que se  $\nabla f(x^0) = 0$ , nada mais é necessário pois  $x^0$  já é solução.

15

$\lambda_{\min}$ ,  $\lambda_{\max}$  são limites para  $\lambda$  que visam manter certa estabilidade numérica. A expressão anterior é a projeção de  $\frac{1}{\|\nabla f(x^0)\|_{\infty}}$  sobre o intervalo  $[\lambda_{\min}, \lambda_{\max}]$ .

Na prática,  $\lambda_{\min} = 10^{-30}$  e  $\lambda_{\max} = 10^{30}$ .

$\lambda \in [\lambda_{\min}, \lambda_{\max}]$  serve ainda para convergência

teórica. (não vamos fazer aqui).

16

2) Se  $s_{k-1}^t y_{k-1} \leq 0$ ,  $\frac{1}{\sigma_k} = \frac{s_{k-1}^t s_{k-1}}{s_{k-1}^t y_{k-1}}$  será negativo ou mesmo não definido. Neste caso tomamos

$$\lambda_k = \lambda_{\max}.$$

ou seja, tenta-se "andar ao máximo" na direção  $-\nabla f(x^k)$ , deixando todo ajuste para a busca linear.

## Sobre o cálculo de $t_k$ (busca linear) [7]

O método

$$x^{k+1} = x^k - t_k \lambda_k \nabla f(x^k), \quad \lambda_k \in [\lambda_{\min}, \lambda_{\max}]$$

converge globalmente se  $t_k > 0$  é calculado como no esquema geral de descida, isto é,

"Armijo + interpolação quadrática  
+ backtracking + salvaguardas".

Porém, se  $t_k < 1$  estaremos descartando 18  
o passo espectral  $\lambda_k$ , que contém informa-  
ção valiosa da equação secante.

Em outras palavras, gostaríamos que  $t_k = 1$   
com frequência, mesmo que eventualmente  
 $f$  aumente. Ou seja, queremos "passos  
verdadeiros" do método espectral

$$x^{k+1} = x^k - \lambda_k \nabla f(x^k).$$



Para tanto,  $t_k > 0$  deve satisfazer a condição de passo "relaxada"

19

$$f(x^k - t \lambda_k \nabla f(x^k)) \leq f_{\max} - t \eta \lambda_k \|\nabla f(x^k)\|^2 \quad (*),$$

onde

$$f_{\max} = \max \{ f(x^k), f(x^{k-1}), \dots, f(x^{k-m}) \},$$

$m > 0$  parâmetro (na prática,  $m = 100$ ).

A busca linear com (\*) é "não monótona" pois permite  $f$  crescer eventualmente.

(10)

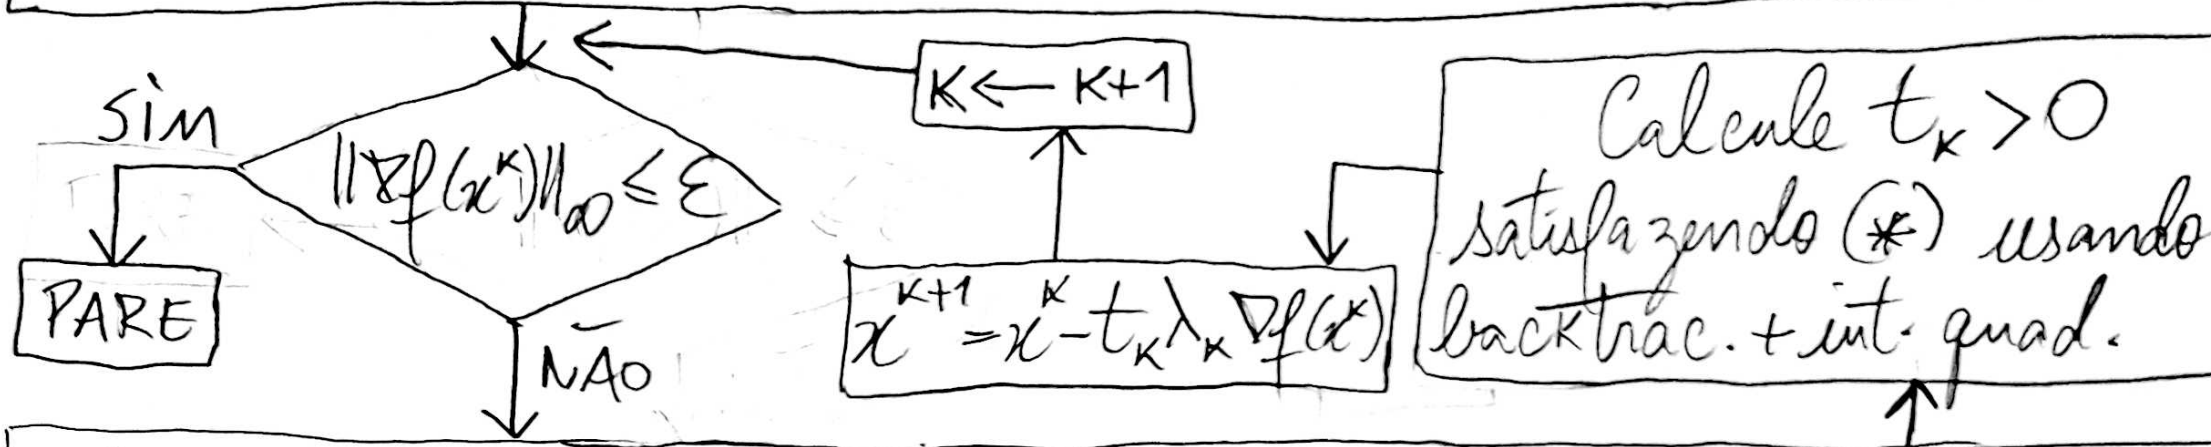
Observe que (\*) é um passo com a direção  $d^k = -\lambda_k \nabla f(x^k)$  trocando  $f(x^k)$  por  $f_{\max}$  (verifique). Claro que "algoritmo tradicional  $\Rightarrow$  (\*)" ( (\*) é mais fraca)

Em implementações, armazenamos o vetor das  $M$  últimas  $f$ , que é iniciado com todas as entradas  $= -\infty$ .

# Método do gradiente espectral

(11)

Dados  $x^0 \in \mathbb{R}^m$ ,  $0 < \lambda_{\min} < \lambda_{\max}$ ,  $M > 0$ ,  $\varepsilon > 0$ ,  $k \leftarrow 0$



Se  $k=0$ ,  $\lambda_0 = \min\{\lambda_{\max}, \max\{\lambda_{\min}, \frac{1}{\|\nabla f(x^0)\|_\infty}\}\}$

Se  $k \geq 1$ ,

$$\lambda_k = \begin{cases} \min\{\lambda_{\max}, \max\{\lambda_{\min}, \frac{s_{k-1}^t s_{k-1}}{s_{k-1}^t y_{k-1}}\}\} & \text{caso } \frac{s_{k-1}^t s_{k-1}}{s_{k-1}^t y_{k-1}} > 0 \\ \lambda_{\max} & \text{caso contrário} \end{cases}$$

## Observações:

(12)

- 1) o método do gradiente espectral é barato (= método gradiente) e logo é adequado a problemas com muitas variáveis.
- 2) numericamente é muito bom para minimizar funções não convexas quaisquer.
- 3) Mesmo com Armijo modificado (\*), a convergência é global.

4) O nome "espectral" vem do fato de

13

$$\sigma_{k+1} = \frac{s_k^t y_k}{s_k^t s_k} \text{ ser um quociente de Rayleigh (que}$$

é usado para descrever autovalores) da seguinte "hessiana média":

$$\tilde{B} = \int_0^1 \nabla^2 f(x^k + ts_k) dt.$$

De fato, defina

$$g(t) = \nabla f(x^k + ts_k), \quad t \in [0, 1].$$

Então

14

$$\int_0^1 g'(t) dt = g(1) - g(0)$$

$$\Rightarrow \int_0^1 \nabla^2 f(x^k + ts_k) s_k dt = \nabla f(x^k + s_k) - \nabla f(x^k) = y_k$$

$$\Rightarrow \left[ \int_0^1 \nabla^2 f(x^k + ts_k) dt \right] s_k = y_k,$$

ou seja,  $\tilde{B} s_k = y_k$ . Logo, temos o quociente de Rayleigh

$$\frac{s_k^t \tilde{B} s_k}{s_k^t s_k} = \frac{s_k^t y_k}{s_k^t s_k} = \sigma_{k+1}.$$