

OTIMIZAÇÃO COM RESTRIÇÕES

PROBLEMA DE PROGRAMAÇÃO NÃO LINEAR (PNL)

$$\begin{cases} \min f(x) & \leftarrow \text{FUNÇÃO OBJETIVO (F.O.)} \\ \text{s.a. } h(x) = 0 & \leftarrow \text{RESTRIÇÕES DE IGUALDADE} \\ g(x) \leq 0 & \leftarrow \text{" " DESIGUALDADE} \end{cases}$$

EXEMPLOS:

1) (PROBLEMA DE PROGRAMAÇÃO LINEAR)

$$\min c^T x$$

$$\text{s.a. } Ax = b$$

$$Cx \leq d$$

2) (PROB. DE PROG. QUADRÁTICA)

$$\min \frac{1}{2} x^T A x + b^T x$$

(A SIMÉTRICA).

$$\text{s.a. } Ax = b$$


$$Cx \leq d$$

3) $\min (x_1 - 2)^2 + (x_2 - 1)^2$

$$\text{s.a. } x_1 + x_2 - 2 \leq 0$$

$$x_1^2 - x_2 \leq 0$$

$$\begin{bmatrix} 2x_1 \\ -1 \end{bmatrix}$$



NOTAÇÃO:

- $\Omega = \{x \in \mathbb{R}^m; h(x)=0, g(x) \leq 0\}$

é o conjunto viável de PNL.

- $x \in \Omega$ é um PONTO VIÁVEL (PONTO FACTÍVEL).

- DEFINIÇÕES USUAIS DE MINIMIZADORES LOCAIS / GLOBAIS.
(SOLUÇÕES ÓTIMAS LOCAIS / GLOBAIS).

OTIMIZAÇÃO IRRESTRITA ($\min f(x)$) : $\nabla f(x^*) = 0$.

// RESTRITA; ADAPTAR $\nabla f(x^*) = 0 \dots$

(CONDIÇÃO NECESSÁRIA DE OTIMALIDADE).

CASO PARTICULAR:


$$\min f(x)$$

$$\text{s.t. } g_1(x) \leq 0$$

$$g_2(x) \leq 0$$

$$g_3(x) \leq 0$$

$$x \in \mathbb{R}^2$$



CASO PARTICULAR:


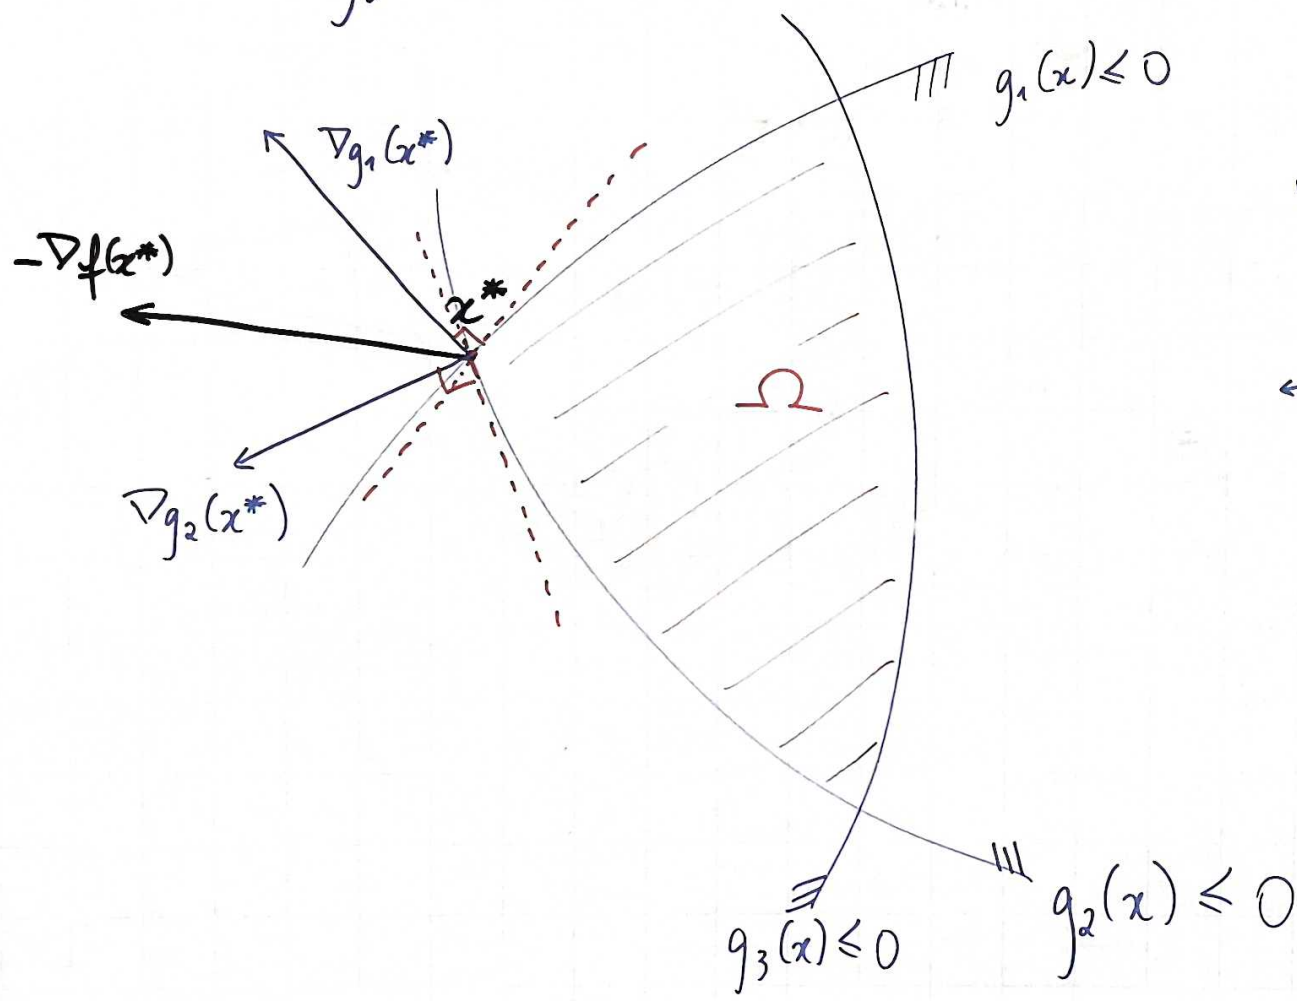
$$\min f(x)$$

$$\text{s.t. } g_1(x) \leq 0$$

$$g_2(x) \leq 0$$

$$g_3(x) \leq 0$$

$$x \in \mathbb{R}^2$$



* f DECRESCER (LOCALMENTE) NA DIREÇÃO $-\nabla f(x^*)$, DADO QUE

$-\nabla f(x^*)$ É DIREÇÃO DE DESCIDA $(-\nabla f(x^*)^T \nabla f(x^*) = -\|\nabla f(x^*)\|^2 < 0)$

* SE CAMINHAMOS NA DIREÇÃO $-\nabla f(x^*)$, SAÍMOS DO CONJUNTO VIÁVEL Ω ...

$\rightarrow x^*$ É UM MINIMIZADOR LOCAL ...

* SE CAMINHARMOS EM QUALQUER DIREÇÃO ENTRE $\nabla g_1(x^*)$ E $\nabla g_2(x^*)$, SAÍMOS DE Ω . MAS SE CAMINHARMOS EM UMA DIREÇÃO PARA FORA DO CONE FORMADO POR ∇g_1 E ∇g_2 , CONSEGUIMOS DIMINUIR f COM PONTOS VIÁVEIS.

(**) $-\nabla f(x^*) = \mu_1 \nabla g_1(x^*) + \mu_2 \nabla g_2(x^*)$, $\mu_1 \geq 0$, $\mu_2 \geq 0$

OU SEJA,

$$\left. \begin{aligned} \nabla f(x^*) + \mu_1 \nabla g_1(x^*) + \mu_2 \nabla g_2(x^*) + \mu_3 \nabla g_3(x^*) &= 0, \\ \mu_1 \geq 0, \mu_2 \geq 0, \mu_3 \geq 0, \\ \mu_1 g_1(x^*) = 0, \mu_2 g_2(x^*) = 0, \mu_3 g_3(x^*) = 0. \end{aligned} \right\} (*)$$

NA FIGURA, $g_1(x^*) = g_2(x^*) = 0$ (PARTICIPAM DA "DESCRIÇÃO" DE x^*) E $g_3(x^*) < 0$ (NÃO PARTICIPA).

→ g_1 E g_2 SÃO ATIVAS EM x^*
→ g_3 É INATIVA EM x^* .

$I(x^*) = \{ i ; g_i(x^*) = 0 \}$: CONJUNTO DOS ÍNDICES
DAS RESTRIÇÕES DE DESIG.
ATIVAS EM x^* .

(*) PODE SER ESCRITO COMO :



$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i=1}^p \mu_i \nabla g_i(x^*) = 0 \\ \mu_i \geq 0 \\ \mu_i g_i(x^*) = 0, \forall i \end{array} \right\} \text{ COMPLEMENTARIDADE.}$$

OU

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i \in I(x^*)} \mu_i \nabla g_i(x^*) = 0 \\ \mu_i \geq 0, i \in I(x^*) \end{array} \right.$$


IGUALDADES ($h(x)=0$):

$m=2$



$$-\nabla f(x^*) = \lambda \nabla h(x^*), \quad \lambda \in \mathbb{R}.$$

$$m=3$$



$$-\nabla f(x^*) = \lambda_1 \nabla h_1(x^*) + \lambda_2 \nabla h_2(x^*) , \quad \lambda_1, \lambda_2 \in \mathbb{R}.$$

CONTANDO TUDO...

$(x^* \text{ VIÁVEL})$

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^p \mu_j \nabla g_j(x^*) = 0 \\ \mu_j \geq 0 \\ \mu_j g_j(x^*) = 0, \quad \forall j. \end{array} \right.$$

λ e μ SÃO OS MULTIPLICADORES DE LAGRANGE.

ESSAS SÃO AS CONDIÇÕES DE KARUSH-KUHN-TUCKER (KKT)

OBS.: QUANDO NÃO HÁ RESTRIÇÕES, AS CONDIÇÕES KKT
SE REDUZEM À $\nabla f(x^*) = 0$.

EXEMPLO: $\min (x_1 - 2)^2 + (x_2 - 1)^2 \quad (f)$
s.a. $x_1 + x_2 - 2 \leq 0 \quad (g_1)$
 $x_1^2 - x_2 \leq 0 \quad (g_2)$

KKT:

$$\begin{cases} \nabla f(x^*) + \mu_1 \nabla g_1(x^*) + \mu_2 \nabla g_2(x^*) = 0 \\ \mu_1 \geq 0, \mu_2 \geq 0 \\ \mu_1 g_1(x^*) = 0, \mu_2 g_2(x^*) = 0 \end{cases}$$

$$\begin{bmatrix} 2(x_1 - 2) \\ 2(x_2 - 1) \end{bmatrix} + \mu_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \mu_2 \begin{bmatrix} 2x_1 \\ -1 \end{bmatrix} = 0 \quad (1)$$

$$\mu_1 \geq 0, \mu_2 \geq 0 \quad (2)$$

$$\mu_1(x_1 + x_2 - 2) = 0, \mu_2(x_1^2 - x_2) = 0. \quad (3)$$

CASO 1: $\mu_1 = 0, \mu_2 = 0$. "DÁ ERRADO:"

(2) E (3) VALEM. DE (1), OBTENHAMOS $x = (2, 1)$.

PORÉM, x NÃO É VIÁVEL ($x_1 + x_2 - 2 = 1 > 0$).

CASO 2: $\mu_1 = 0, \mu_2 > 0$.


(VAI DAR ERRADO : (FAÇA!))

CASO 3: $\mu_1 > 0, \mu_2 = 0$

(VAI DAR ERRADO : (FAÇA!)

CASO 4: $\mu_1 > 0, \mu_2 > 0 \rightarrow \text{DÁ CERTO ;)}$

ESSE CASO ADMITE A SOLUÇÃO $x^* = (1, 1)$.



• x^* é viável.

• x^* é KKT:

$$\begin{bmatrix} -2 \\ 0 \end{bmatrix} + \mu_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \mu_2 \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 0, \quad \mu_1 \geq 0, \\ \mu_2 \geq 0$$

↳ MULTIPLICADORES: $\mu_1 = \mu_2 = \frac{2}{3} > 0$.

CONDIÇÕES DE KARUSH-KUHN-TUCKER (KKT)

(CONTINUAÇÃO)

MINIMIZAÇÃO IRRESTRITA: $\min f(x)$.

→ x^* é minimizador $\Rightarrow \nabla f(x^*) = 0$.

→ $\nabla f(x^*) = 0 \not\Rightarrow x^*$ é minimizador. (P. ex., $f(x) = -x^2$, $x^* = 0$).

→ se f é convexa,
 $\nabla f(x^*) = 0 \Rightarrow x^*$ é minimizador.

OBJETIVO: VERIFICAR ESSAS AFIRMAÇÕES PARA OTIMIZAÇÃO RESTRITA (KKT).

$$\left. \begin{array}{l} \min f(x) \\ \text{s.t. } h(x) = 0 \\ g(x) \leq 0 \end{array} \right\} \text{"PNL"}$$

x^* é KKT se é viável ($h(x^*) = 0, g(x^*) \leq 0$)

e se existem $\mu \in \mathbb{R}^p$ e $\lambda \in \mathbb{R}^m$ tais que

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^p \mu_j \nabla g_j(x^*) = 0 \\ \mu_j \geq 0, \quad \forall j \\ \mu_j g_j(x^*) = 0, \quad \forall j \end{array} \right.$$

SE x^* É MINIMIZADOR DE PNL, ENTÃO x^* É KKT ????

EXEMPLO 1: $\min x$

$$\text{s.a. } x^2 \leq 0$$

$x^* = 0$ É O ÚNICO MINIMIZADOR, DADO QUE É O ÚNICO

PONTO VIÁVEL.

KKT: $1 + \mu 2x = 0$, $\mu \geq 0$, $\mu x^2 = 0$.

PARA $x^* = 0$, A PRIMEIRA EQUAÇÃO NÃO VALE PARA QUALQUER $\mu \geq 0$. OU SEJA, $x^* = 0$ NÃO É KKT.

RESPOSTA: NÃO!

O QUE FALTA PARA x^* SER KKT SEMPRE ?


NO EXEMPLO, A DERIVADA DA RESTRIÇÃO $g(x) = x^2$ É NULA EM x^* ...

O PROBLEMA É QUE "OS GRADIENTES DAS RESTRIÇÕES $h(x) = 0$ E DAS RESTRIÇÕES DE DESIGUALDADE $g_j(x) \leq 0$ ATIVAS EM x^* ($g_j(x^*) = 0$) SÃO L.D."

EXEMPLO 2: $\min x_1$

$$\text{s.o. } x_2 - x_1^3 \leq 0$$

$$-x_2 - x_1^3 \leq 0$$



$x^* = (0,0)$ é o MINIMIZADOR.

KKT:

$$g_1(0,0) = 0$$

$$g_2(0,0) = 0$$

$\rangle g_1 \text{ e } g_2 \text{ S\AA O ATIVAS EM } (0,0).$

$$\nabla f(0,0) + \mu_1 \nabla g_1(0,0) + \mu_2 \nabla g_2(0,0) = 0, \quad \mu_1, \mu_2 \geq 0.$$

$$\mu_1 g_1(0,0) = \mu_2 g_2(0,0) = 0 \quad \checkmark$$

$$\begin{bmatrix} 1 \\ 0 \end{bmatrix} + \mu_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix} + \mu_2 \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mu_1, \mu_2 \geq 0.$$

É IMPOSSÍVEL $\Rightarrow x^* = (0,0)$ NÃO É KKT.

PROBLEMA: $\nabla g_1(0,0)$ e $\nabla g_2(0,0)$ S\AA O L.D's.

DEFINIÇÃO: UM PONTO VIÁVEL x^* É REGULAR SE
OS GRADIENTES

$$\nabla h_i(x^*), \forall i \text{ E}$$

$$\nabla g_j(x^*), \forall j \text{ TAL QUE } g_j(x^*) = 0$$

SÃO L.I.'s.

TEOREMA: SEJA x^* UM MINIMIZADOR DE PNL. SE x^* É
REGULAR, ENTÃO É x^* É KKT.

(MIN. + REGULARIDADE \Rightarrow KKT)


OBS.: É POSSÍVEL ENFRAQUECER A HIPÓTESE DE REGULARIDADE.

EXEMPLO:

$$\min (x_1 - 1)^2 + (x_2 - 2)^2$$

$$\text{s.t. } x_1 + x_2 - 2 \leq 0$$

$$x_1^2 - x_2 \leq 0$$



O MINIMIZADOR $x^* = (1, 1)$ É KKT:

$$\begin{bmatrix} -2 \\ 0 \end{bmatrix} + \mu_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \mu_2 \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 0, \quad \mu_1, \mu_2 \geq 0 \quad (*)$$

$$\mu_1 (x_1^* + x_2^* - 2) = 0, \quad \mu_2 ((x_1^*)^2 - x_2^*) = 0.$$

A SOLUÇÃO DE (*) É $\mu_1 = \frac{2}{3}$, $\mu_2 = \frac{2}{3}$.

OBSERVE QUE OS GRADIENTES $\nabla g_1(x^*) = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ E
 $\nabla g_2(x^*) = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$ SÃO L.I.'S (g_1 E g_2 SÃO ATIVAS EM x^*)

KKT e CONVEXIDADE

$$\begin{aligned} \text{PNL : } \quad & \min f(x) \\ & \text{s.a. } h(x) = 0 \\ & g(x) \leq 0 \end{aligned}$$

PNL CONVEXO : f e g_i SÃO CONVEXAS,
 h_i SÃO LINEARES

TEOREMA (KKT É SUFICIENTE PARA OTIMALIDADE EM PROBLEMAS CONVEXOS)

SEJA UM PNL CONVEXO. SE x^* É KKT ENTÃO
 x^* É UM MINIMIZADOR (GLOBAL).

IDEIA DA PROVA (EXERCÍCIO).

1) POR HIPÓTESE, x^* É KKT. ENTÃO EXISTEM

μ E λ TAIS QUE

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^p \mu_j \nabla g_j(x^*) = 0, \quad (*)$$

$$\mu_j \geq 0, \quad \forall j, \quad \text{E} \quad \mu_j g_j(x^*) = 0, \quad \forall j.$$

2) MULTIPLIQUE POR $(x - x^*)$, ONDE x É UM PONTO VIÁVEL QUALQUER.

3) USE O FATO QUE $z(x) - z(x^*) \geq \nabla z(x^*)^T (x - x^*)$ QUANDO z É CONVEXA.

4) USE A VIABILIDADE DE x E x^* PARA CONCLUIR QUE $f(x) \geq f(x^*)$.

EXEMPLO (PROGRAMAÇÃO LINEAR).

$$PL: \min w^T x$$

$$\text{s.a. } Ax - b = 0$$

$$Cx - d \leq 0$$

PL é convexo. Logo, se x^* é KKT então x^* é minimizador (GLOBAL) DE PL.

$$\underline{KKT}: w + A^T \lambda + C^T \mu = 0$$

$$\mu \geq 0$$

$$\mu^T (Cx - d) = 0$$

ESSE SISTEMA KKT É RELATIVAMENTE SIMPLES. O "ÚNICO" COMPLICADOR É A CONDIÇÃO $\mu^T (Cx - d) = 0$.

OBS.: SE NÃO HÁ DESIGUALDADES,

$$\min w^T x$$

$$\text{s.a. } Ax = b,$$

ENTÃO KKT É MUITO SIMPLES:

$$w + A^T \lambda = 0 \quad (\text{UM SISTEMA LINEAR EM } \lambda).$$

INSERINDO FOLGAS, PL PODE SER ESCRITO COMO

$$\min w^T x \quad \text{s.a. } Ax = b, \quad x \geq 0.$$

KKT:

$$\begin{cases} b + A^T \lambda - \mu = 0 \\ \mu \geq 0 \\ \mu^T x = 0 \end{cases}$$

$$(Ax = b, x \geq 0)$$

$$\begin{cases} \mu = b + A^T \lambda \geq 0 \\ \mu^T x = 0 \end{cases}$$

$$\begin{cases} b + A^T \lambda \geq 0 \\ (b + A^T \lambda)^T x = 0 \end{cases}$$

MÉTODO INSPIRADO
NESSE SISTEMA

KKT:

"MÉTODO DOS

PONTOS INTERIORES"

(CPLEX, GUROBI
ETC...)