

# Gradiente Projetado

L1

$$\min f(x) \text{ s.a. } x \in C,$$

onde  $C \subset \mathbb{R}^n$  é convexo e fechado.

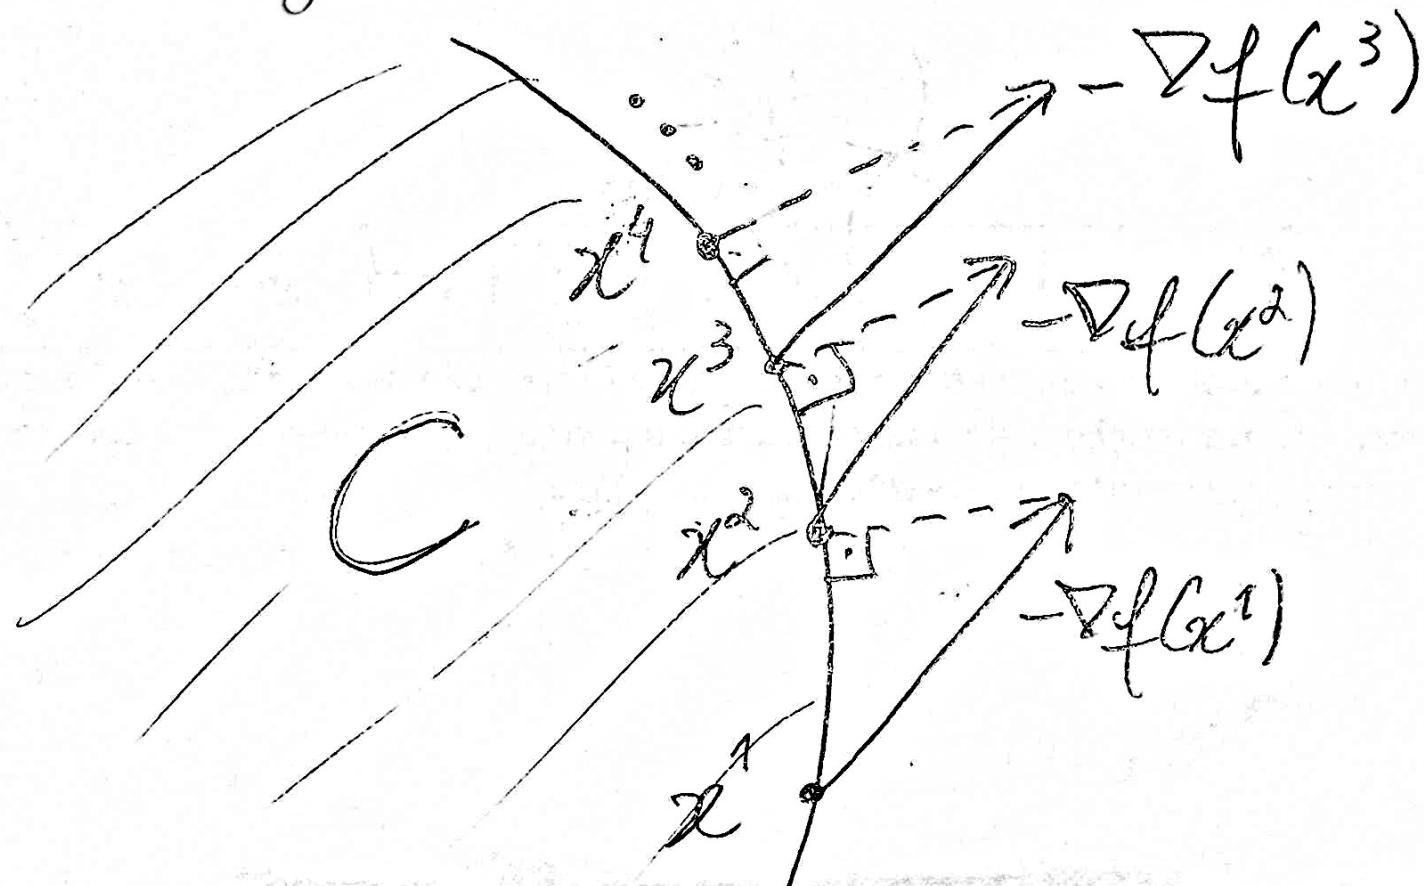
Sóleia: Adaptar o método do gradiente

$$x^{k+1} = x^k - t_k \nabla f(x^k)$$

para garantir viabilidade:

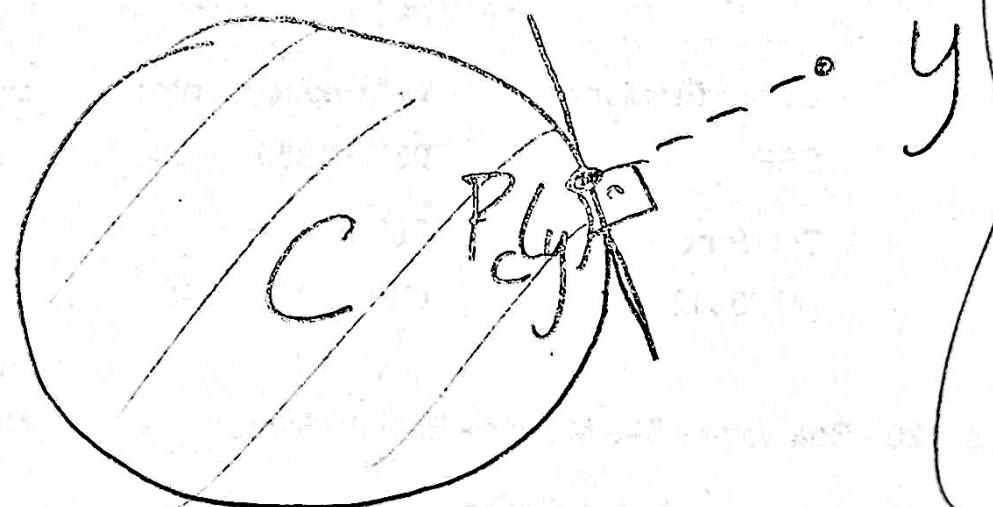
$$x^{k+1} \in C.$$

Como? Calcule  $x^{k+1}$  e  
"converte" a viabilidade projetando  
no conjunto  $C$ . L2



O que é projetar sobre C? 3

- C projeção de um ponto  $y \in \mathbb{R}^n$  em C  
é o ponto  $P_C(y) \in C$  mais  
proximo à  $y$ .



$P_C(y)$  é  
a projeção  
de  $y$  sobre  
C!

Queremos que  $x^* = P_C(y)$  é a solução de  
do problema

$$\min_x \frac{1}{2} \|x - y\|^2 \text{ s.t. } x \in C.$$

Teorema: Se  $C \neq \emptyset$  é convexo e  
fechado então  $P_C(y)$  está bem  
definida (a projeção é única para  
cada  $y \in \mathbb{R}^m$ ).

De fato, o problema de projeção é  
 $\min_x p(x) = \frac{1}{2} \|x - y\|^2$  s.a.  $x \in C$  é  
váml, dado que  $C \neq \emptyset$ . Agora,  
 $p(x) = \frac{1}{2} x^t I x + y^t x + \text{cte}(y)$  é  
uma quadrática estritamente convexa  
(sua Hessiana é  $I > 0$ ). Logo  
este problema admite minimizado global.

Mas como este problema é convexo 6  
pois  $C$  é conjunto convexo, então  
admite único minimizador global.

$x^*$ : se  $\bar{x}$  e  $\tilde{x}$  forem minimizadores  
distintos então  $\frac{1}{2}\bar{x} + \frac{1}{2}\tilde{x} \in C$  e  
 $p\left(\frac{1}{2}\bar{x} + \frac{1}{2}\tilde{x}\right) < \frac{1}{2}p(\bar{x}) + \frac{1}{2}p(\tilde{x}) = p^*$ ,  
uma contradição. ■

$$P_C(y) = \arg \min_{x \in C} \frac{1}{2} \|x - y\|^2, \quad (*) \quad (\exists$$

$C + \phi$  convexo,  
fechado.

Como calcular  $P_C(y)$  ?

• Resolvendo (\*) via KKT, para conjuntos  $C$  específicos.

(lembre-se que KKT é suficiente para otimalidade em problemas convexos).

$$1) C = \{x \in \mathbb{R}^n; Ax = b\}, \quad L8$$

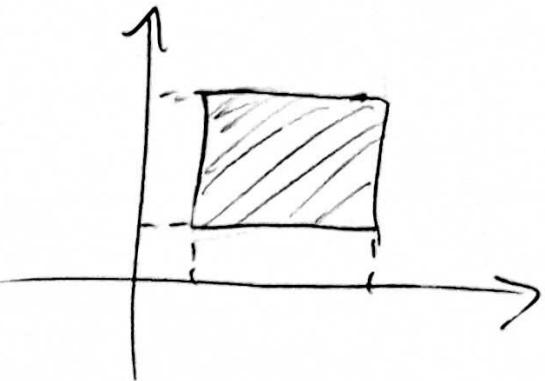
$A_{m \times n}$ , posto  $A = m$ .

EXERCÍCIO: Use as condições KKT para  
mostrar que

$$P_C(y) = (I - A^t (AA^t)^{-1} A)y + A^t (AA^t)^{-1} b$$

(compare com a expressão (L.2) do  
livro de Cna, Página 57)

2)  $C = \{x \in \mathbb{R}^n; l_i \leq x_i \leq u_i, \forall i\}$   
 (caixa,  $l_i < u_i, \forall i$ )



Problema projeção:

$$\min \frac{1}{2} \|x-y\|^2 \text{ s.t. } -x+l \leq 0, x-u \leq 0$$

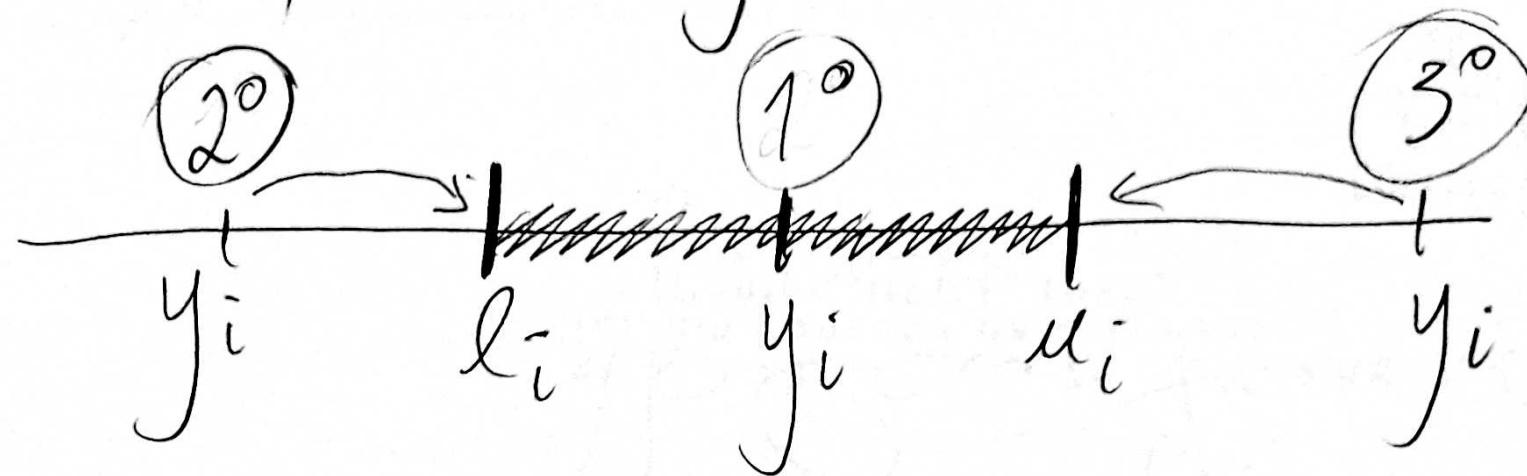
KKT:  $(x^*-y) - \mu^l + \mu^u = 0 \quad (1)$

$$\mu^l \geq 0, \mu^u \geq 0, l \leq x^* \leq u \quad (2)$$

$$\mu_i^l(-x_i^* + l_i) = \mu_i^u(x_i^* - u_i) = 0, \forall i \quad (3)$$

3 casos para  $y_i$ :

10



$l_i < y_i < u_i$ : Com fun de satisfazer

KKT, basta tomar

$$x_i^* = y_i \text{ e}$$

$$\mu_i^l = \mu_i^u = 0.$$

•  $y_i \leq l_i$  : tomar  $x_i^* = l_i$ , (11)

$$\mu_i^l = x_i^* - y_i \geq 0 \quad \text{e} \quad \mu_i^u = 0.$$

•  $y_i \geq u_i$  : tomar  $x_i^* = u_i$ ,  $\mu_i^l = 0$

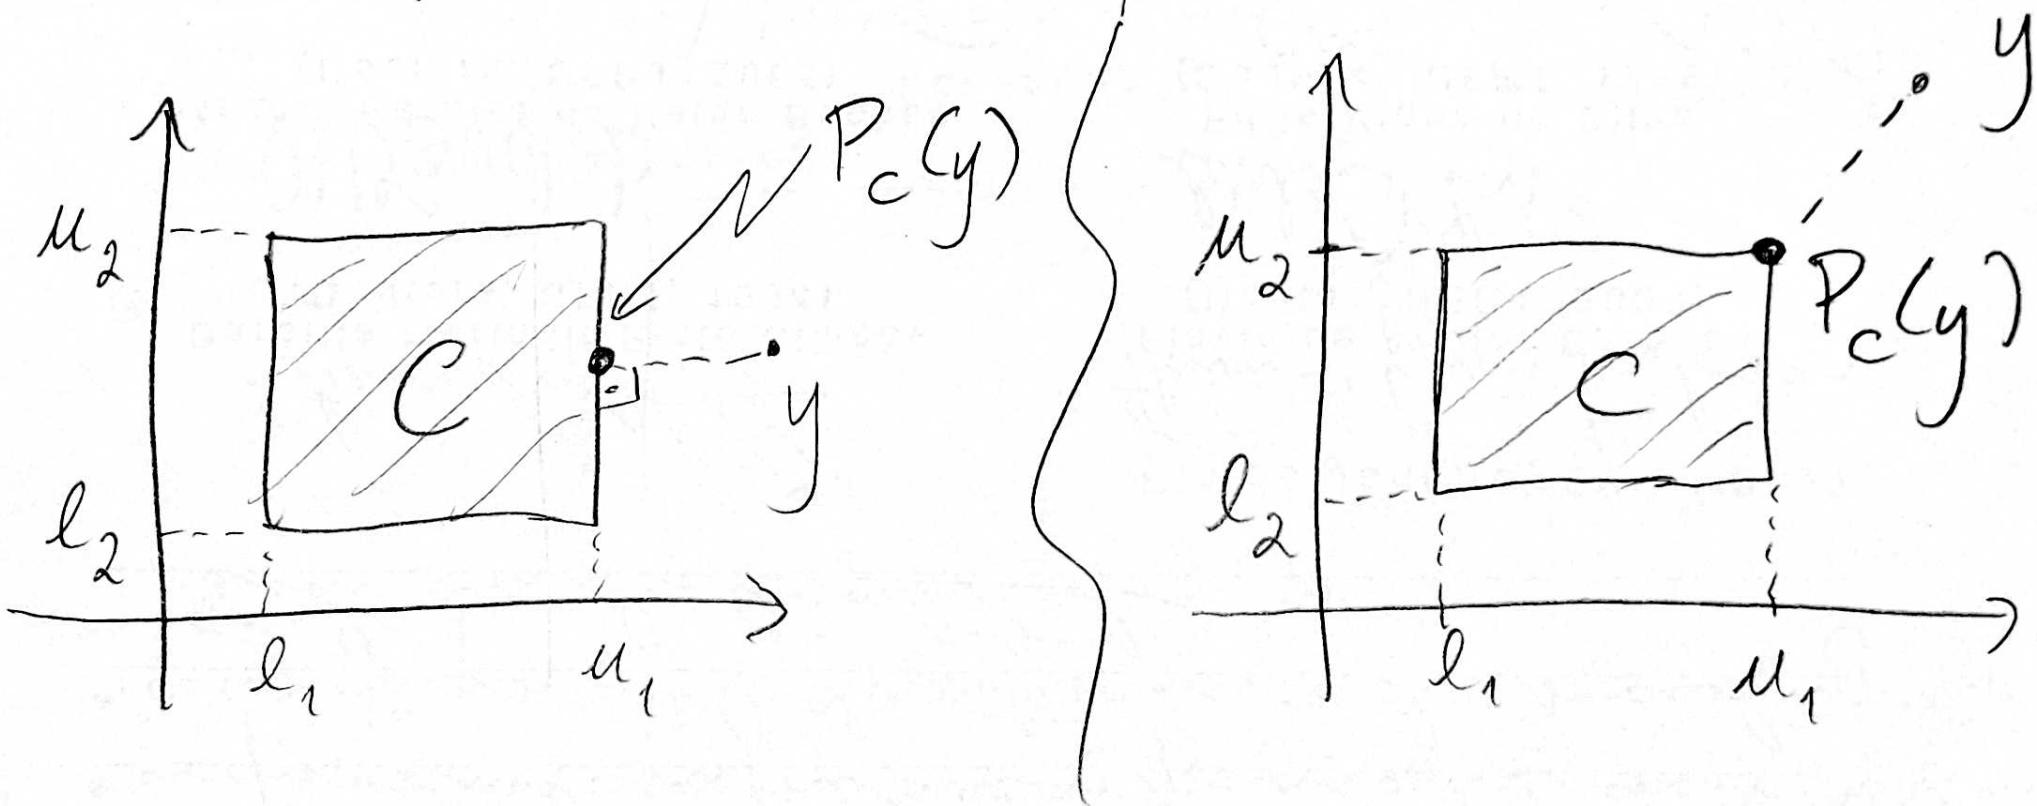
$$\text{e} \quad \mu_i^u = y_i - x_i^* \geq 0.$$

Em resumo:

$$[P_C(y)]_i = \begin{cases} l_i & \text{se } y_i \leq l_i \\ y_i & \text{se } l_i < y_i < u_i \\ u_i & \text{se } y_i \geq u_i \end{cases}$$

Em implementações, fazemos,  $\hat{v}_i$ ,  $P_c(y)$   
[ $P_c(y)$ ] $_i = \min\{u_i, \max\{l_i, y_i\}\}$

(verifique que essa é a projeção)



Como para? Ou, o que é KKT para o problema original

$$\min f(x)$$

s.a.  $l_i \leq x_i \leq u_i, \forall i$ ?

Resposta:  $x^*$  é KKT se, e somente se,  $P_C(x^* - \nabla f(x^*)) - x^* = 0$ .

(EXERCÍCIO)

# Quais direções tomar?

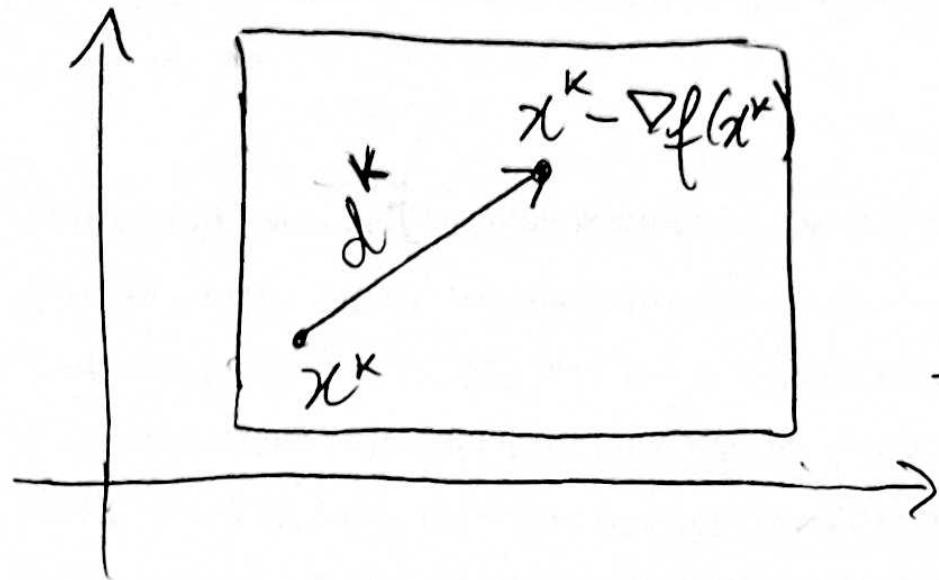
L14

- $d^k = -\nabla f(x^k) \rightarrow \min.$  sem restrições.  
↳  $x^{k+1} = x^k - t_k \nabla f(x^k), t_k > 0.$
- Restrições de caixa:  
$$d^k = P_C(x^k - \nabla f(x^k)) - x^k.$$

Observe que se  $x^k - \nabla f(x^k) \in C$  então

$$d^k = (x^k - \nabla f(x^k)) - x^k = -\nabla f(x^k)$$

(15)



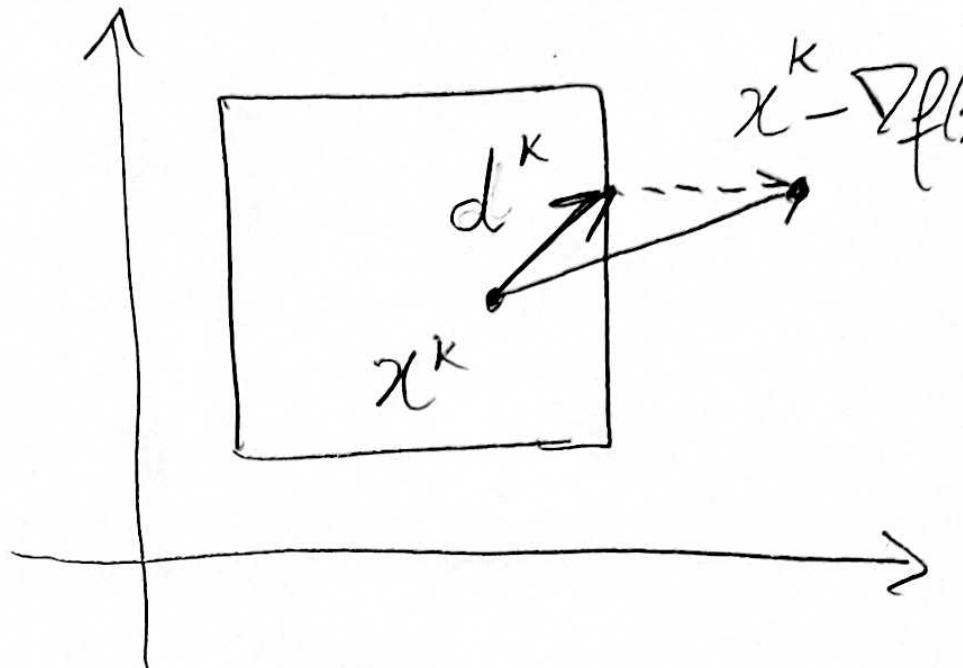
(passo dentro da  
caixa = passo min.  
sem restrições).

Agora, se  $x^k - \nabla f(x^k) \notin C$ , então

$$x^k + d^k \in C.$$

EXERCÍCIO: mostre

~~que~~ que  $x^k + d^k \in C$ .



Conclusão: pela convexidade de  $\underline{L}^{16}$

$C$ , temos  $x^k + t_k d^k \in C$ ,

$\forall t \in [0, 1]$ . Então podemos realizar

uma busca linear em  $t_k \in [0, 1]$

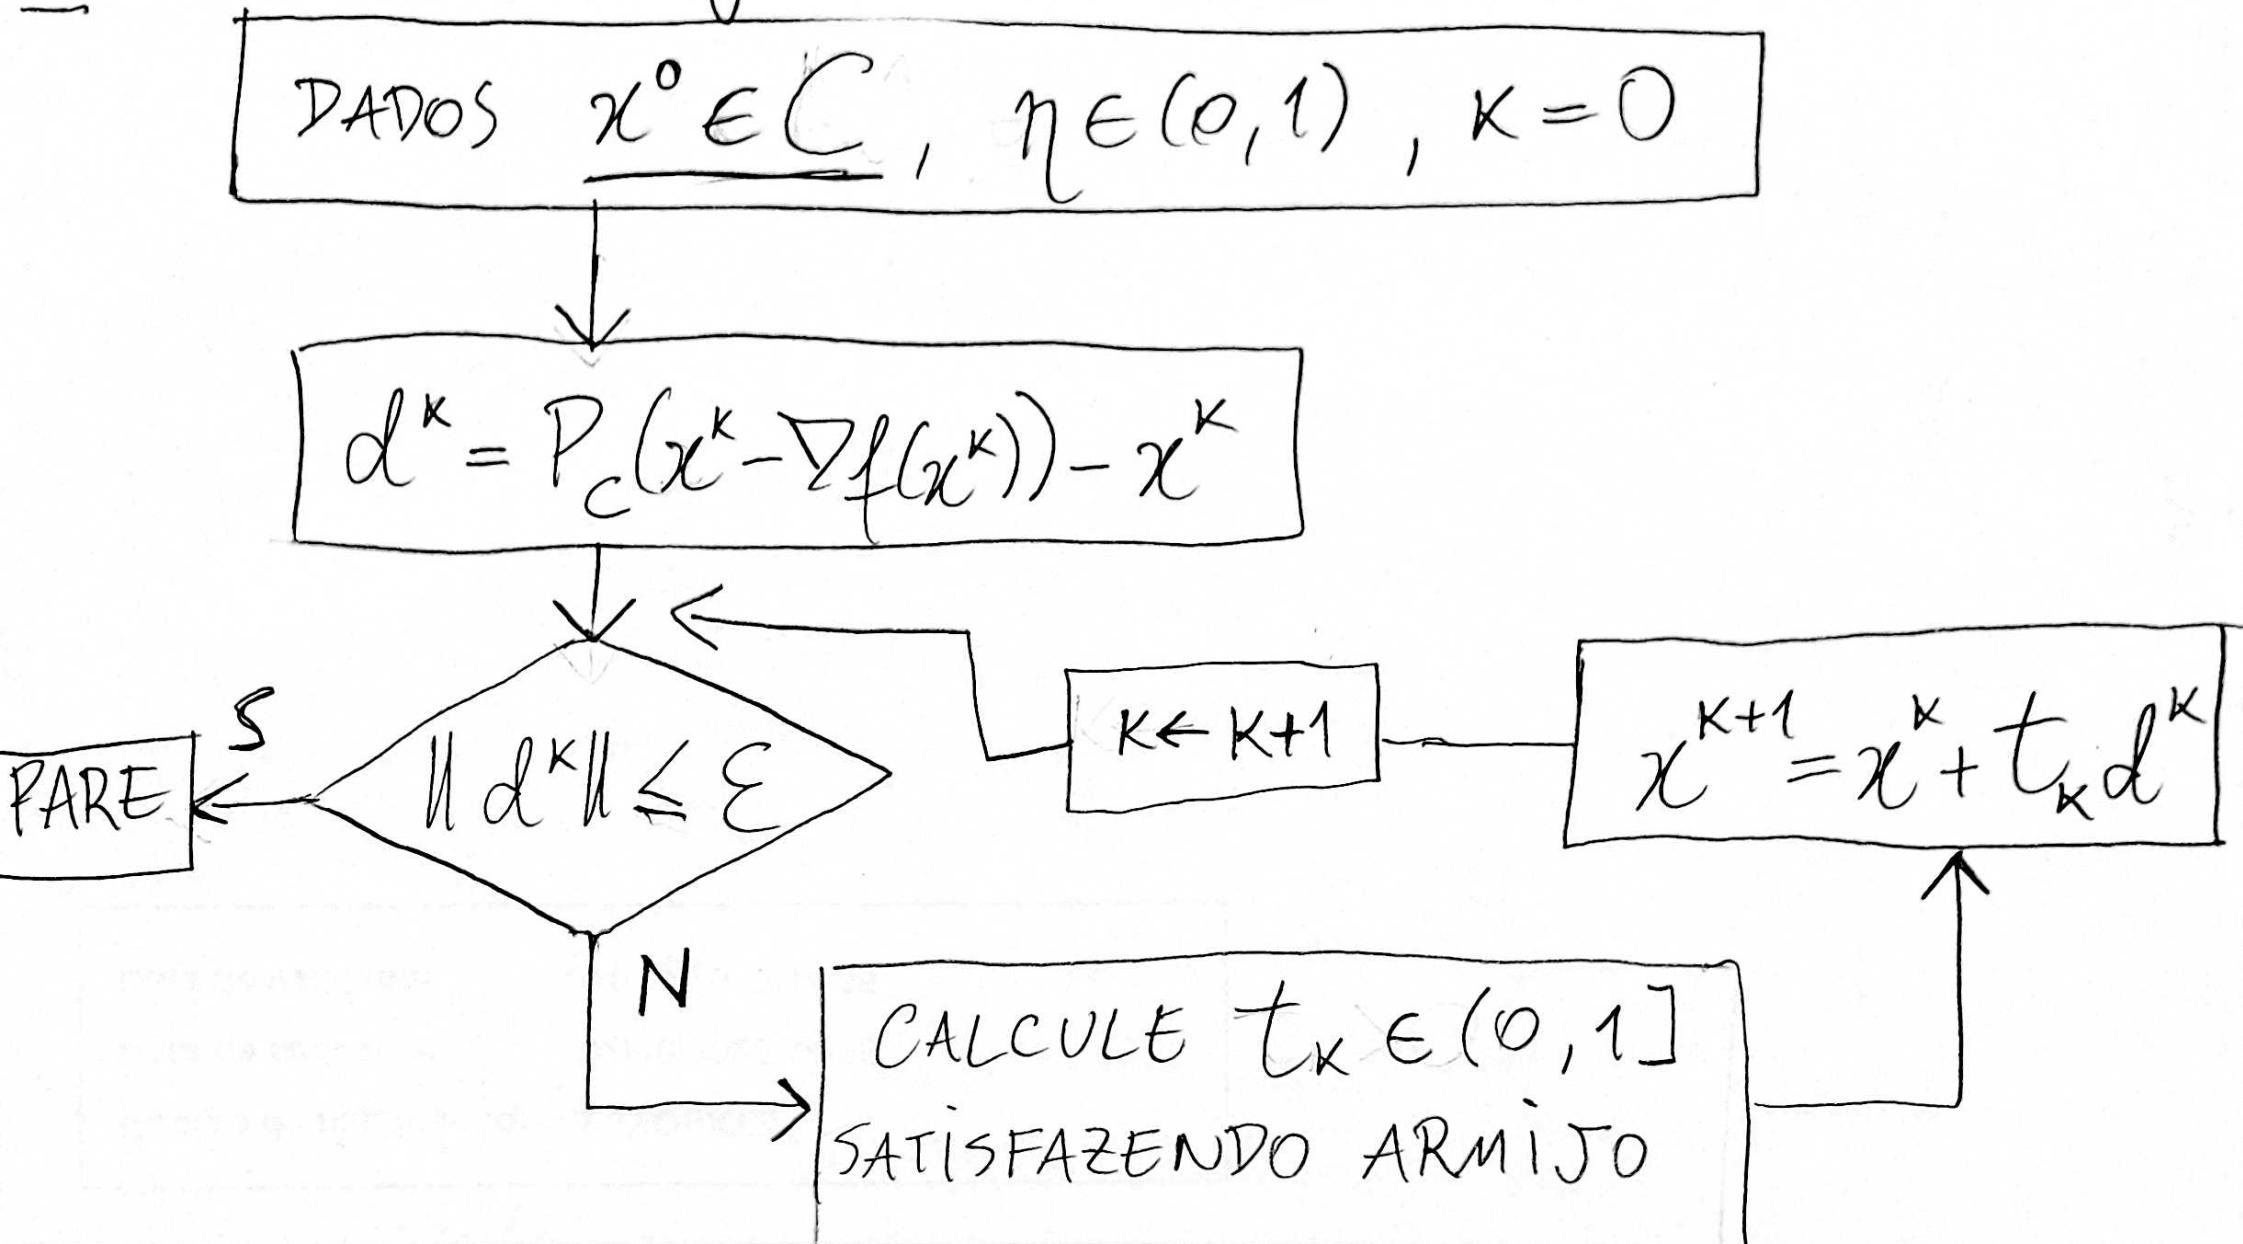
(Armijo), e definir

$$x^{k+1} = x^k + t_k d^k \quad (\in C) \quad \text{III}$$

ooo

# Método do gradiente projetado

17



## Observações:

1) Calcular  $t_k \in (0, 1]$  satisfazendo  
 Armijo se faz da mesma maneira que  
 no esquema geral de descida.

Aliás,  $d^k = P_C(x^k - \gamma f(x^k)) - x^k$  é  
 uma direção de descida para  $f$  a  
 partir de  $x^k$  !! (não vou provar :()

2) É exigido que o ponto inicial pertença à C ( $x^0 \in C$ ).

Na prática

- Escolhemos qualquer  $x^0 \in \mathbb{R}^n$ ;
- Atualizamos  $x^0 \leftarrow P_C(x^0)$ .