

# Gradiente Projetado

L1

$\min f(x)$  s.a.  $x \in C$ ,

onde  $C \subset \mathbb{R}^n$  é convexo e fechado.

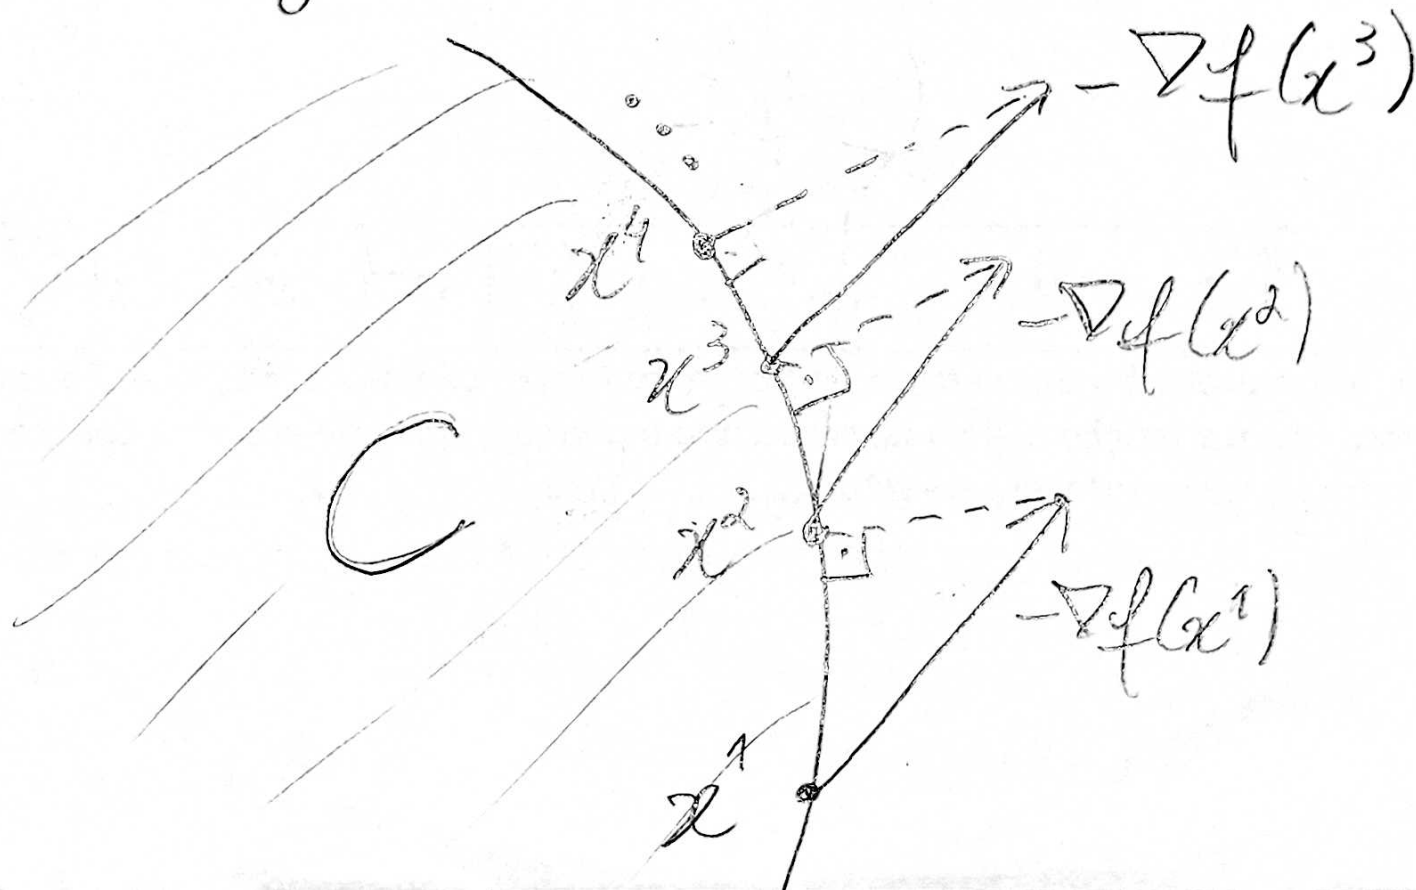
Ideia: Adaptar o método do gradiente

$$x^{k+1} = x^k - t_k \nabla f(x^k)$$

para garantir viabilidade:


$$x^{k+1} \in C.$$

Como? Calcule  $x^{k+1}$  e  
"corrija" a viabilidade projetando  
no conjunto  $C$ . L2



O que é projetar sobre  $C$ ? 13

• A projeção de um ponto  $y \in \mathbb{R}^n$  em  $C$  é o ponto  $P_C(y) \in C$  mais próximo a  $y$ .



$P_C(y)$  é a projeção de  $y$  sobre  $C$ .

ou seja,  $x^* = P_C(y)$  é a solução <sup>4</sup>  
do problema

$$\min_x \frac{1}{2} \|x - y\|^2 \text{ s.a. } x \in C.$$


Teorema: Se  $C \neq \emptyset$  é convexo e  
fechado então  $P_C(y)$  está bem  
definida (a projeção é única para  
cada  $y \in \mathbb{R}^m$ ).

De fato, o problema de projeção [5]  
 $\min_x p(x) = \frac{1}{2} \|x - y\|^2$  s.a.  $x \in C$  é  
viável, dado que  $C \neq \emptyset$ . Agora,  
 $p(x) = \frac{1}{2} x^t I x - y^t x + \text{cte}(y)$  é  
uma quadrática estritamente convexa  
(sua Hessiana é  $I > 0$ ). Logo  
este problema admite minimizador  
global.

Mas como este problema é convexo [6  
(pois  $C$  é conjunto convexo), então  
admite único minimizador global

$x^*$ : Se  $\bar{x}$  e  $\tilde{x}$  fossem minimizadores  
distintos então  $\frac{1}{2}\bar{x} + \frac{1}{2}\tilde{x} \in C$  e

$$P\left(\frac{1}{2}\bar{x} + \frac{1}{2}\tilde{x}\right) < \frac{1}{2}P(\bar{x}) + \frac{1}{2}P(\tilde{x}) = P^*,$$

uma contradição. 

$$P_C(y) = \arg \min_{x \in C} \frac{1}{2} \|x - y\|^2, \quad (*) \quad [7]$$

$C \neq \emptyset$  convexo,  
fechado.

Como calcular  $P_C(y)$ ?

- Resolvendo (\*) via KKT, para conjuntos  $C$  específicos.

(Lembre-se que KKT é suficiente para otimalidade em problemas convexos).



$$1) C = \{x \in \mathbb{R}^n; Ax = b\}, \quad \text{L2}$$

$A$   $m \times n$ , posto  $A = m$ .


EXERCÍCIO: Use as condições KKT para mostrar que

$$P_C(y) = (I - A^t(AA^t)^{-1}A)y.$$

(compare com a expressão (2.2) do livro de Lima, página 57)



$$2) C = \{x \in \mathbb{R}^n; l_i \leq x_i \leq u_i, \forall i\} \\ \text{(caixa, } \underline{l_i < u_i, \forall i})$$



Problema projeção:


$$\min \frac{1}{2} \|x - y\|^2 \text{ s.a. } -x + l \leq 0, x - u \leq 0$$

$$\underline{\text{KKT}}: (x^* - y) - \mu^l + \mu^u = 0 \quad (1)$$

$$\mu^l \geq 0, \mu^u \geq 0, l \leq x^* \leq u \quad (2)$$

$$\mu_i^l (-x_i^* + l_i) = \mu_i^u (x_i^* - u_i) = 0, \forall i \quad (3)$$

3 casos para  $y_i$ :



•  $l_i < y_i < u_i$ . A fim de satisfazer KKT, basta tomar  $x_i^* = y_i$  e  $\mu_i^l = \mu_i^u = 0$ .

•  $y_i \leq l_i$  : tomar  $x_i^* = l_i$  , 11

$$\mu_i^l = x_i^* - y_i \geq 0 \quad \text{e} \quad \mu_i^u = 0.$$

•  $y_i \geq u_i$  : tomar  $x_i^* = u_i$  ,  $\mu_i^l = 0$

$$\text{e} \quad \mu_i^u = y_i - x_i^* \geq 0.$$


Em resumo:

$$[P_c(y)]_i = \begin{cases} l_i & \text{se } y_i \leq l_i \\ y_i & \text{se } l_i < y_i < u_i \\ u_i & \text{se } y_i \geq u_i \end{cases}$$

Em implementações, fazemos,  $\forall i$ , 12

$$[P_C(y)]_i = \min\{u_i, \max\{l_i, y_i\}\}$$

(verifique que essa é a projeção)



Como para? Ou, o que é 13  
KKT para o problema original

min  $f(x)$

s.a.  $l_i \leq x_i \leq u_i, \forall i$ ?

Resposta:  $x^*$  é KKT se, e somente se,  
 $P_c(x^* - \nabla f(x^*)) - x^* = 0$ .  
(EXERCÍCIO)

# Quais direções tomar?

14

- $d^k = -\nabla f(x^k) \rightarrow \text{min. sem restrições.}$


- $\hookrightarrow x^{k+1} = x^k - t_k \nabla f(x^k), t_k > 0.$

- Restrições de caixa:

$$d^k = P_C(x^k - \nabla f(x^k)) - x^k.$$

Observe que se  $x^k - \nabla f(x^k) \in C$  então

$$d^k = (x^k - \nabla f(x^k)) - x^k = -\nabla f(x^k)$$




(passo dentro da  
caixa = passo min.  
sem restrições).

(15)

Agora, se  $x^k - \nabla f(x^k) \notin C$ , então  
 $x^k + d^k \in C$ .

EXERCÍCIO: mostre  
que  $x^k + d^k \in C$ .





Conclusão: pela convexidade de  $\mathbb{L}$   
 $C$ , temos  $x^k + t_k d^k \in C$ ,

$\forall t \in [0, 1]$ . Então podemos realizar  
uma busca linear em  $t_k \in [0, 1]$

(Biseção), e definir

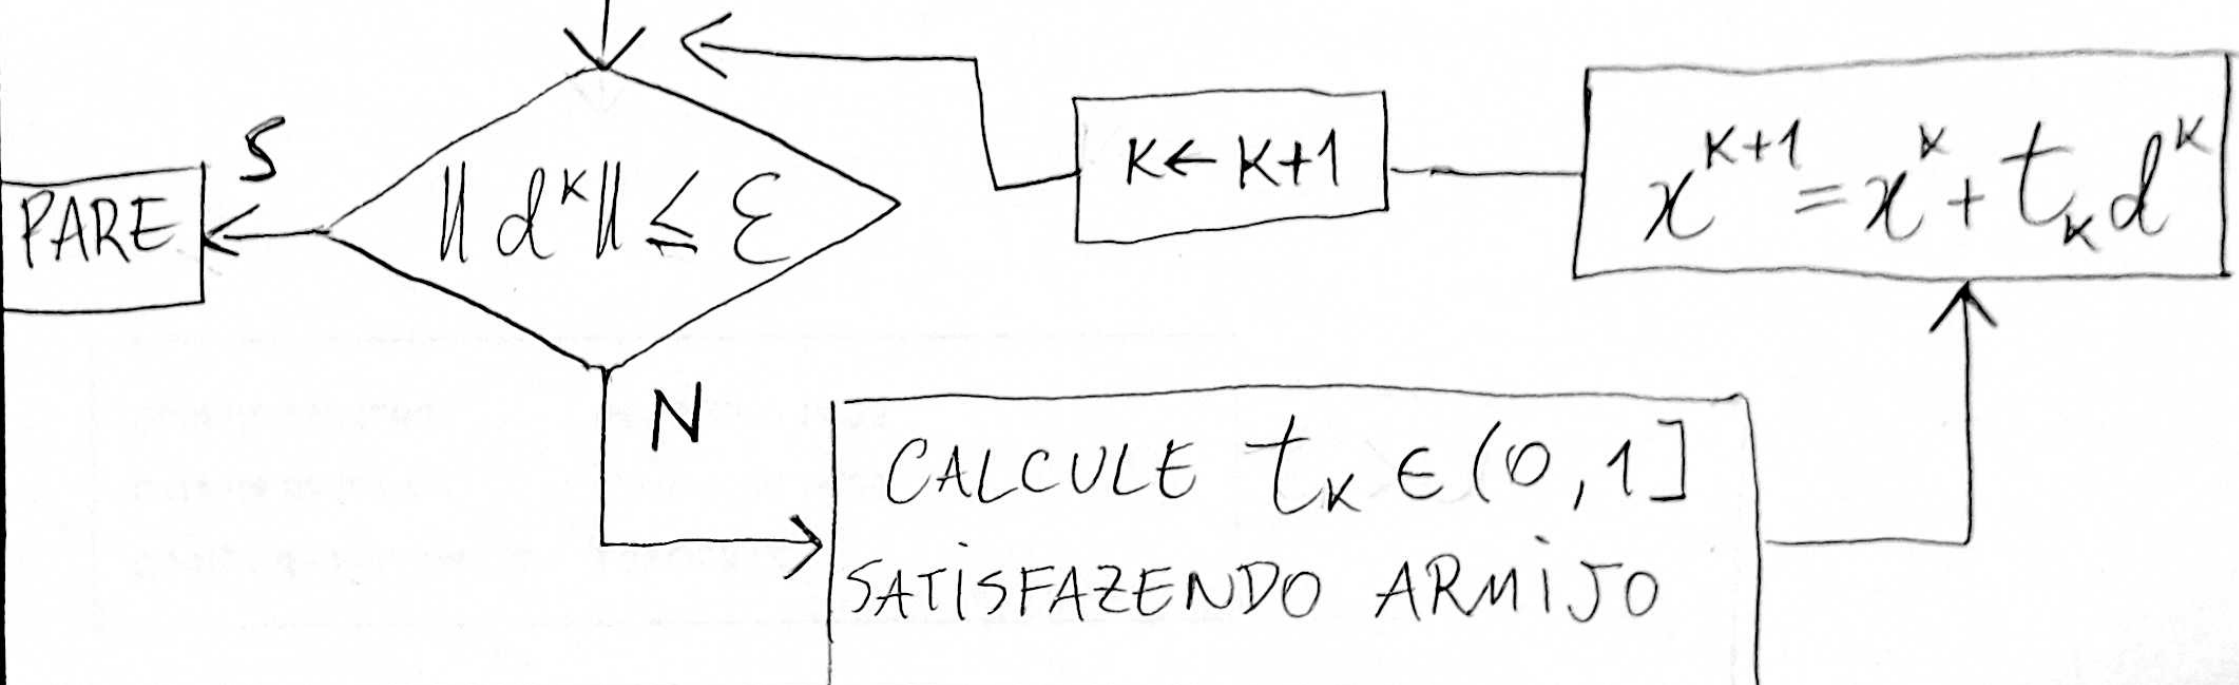
$$x^{k+1} = x^k + t_k d^k \quad (\in C) \quad \begin{array}{c} \text{!!!} \\ \text{ooo} \end{array}$$

# Método do gradiente projetado

17

DADOS  $x^0 \in \mathbb{R}^m$ ,  $\eta \in (0, 1)$ ,  $k = 0$

$$d^k = P_C(x^k - \nabla f(x^k)) - x^k$$



Observação:

18

Calcular  $t_k \in (0, 1]$  satisfazendo  
Armijo se faz da mesma maneira que  
no esquema geral de descida.

Aliás,  $d^k = P_C(x^k - \nabla f(x^k)) - x^k$  é  
uma direção de descida para  $f$  a  
partir de  $x^k$  !! (não vou provar :())