

## Regiões de confiança - métodos específicos

No esquema geral, devemos calcular d<sup>k</sup> solução aproximada do modelo

$$\min_d m(d) = f(x^k) + \nabla f(x^k)^t d + \frac{1}{2} d^t B_k d$$

s.a.  $\|d\| \leq \Delta_k$ .

Para garantir convergência, d<sup>k</sup> deve satisfazer a hipótese H3 (veja anotações sobre convergência).

O objetivo é discutir diferentes formas de fazer isso.

### 1ª forma: passo de Cauchy

Suponhamos que  $d^k = -t_k \nabla f(x^k)$ , onde  $t_k > 0$  é solução de  $\min_t m(-t \nabla f(x^k))$  s.a.  $\|t \nabla f(x^k)\| \leq \Delta_k$ . ( $\|\cdot\|$  = norma Euclidiana)


Resolvendo (omitindo  $x^k$ ):

• Se  $\nabla f^t B_k \nabla f \leq 0$  então o termo quadrático

$d^t B_k d = t^2 \nabla f^t B_k \nabla f \leq 0$  não influencia na minimização

ção, e a solução estará na borda:

$$\|t_k \nabla f\| = \Delta_k \Rightarrow t_k = \frac{\Delta_k}{\|\nabla f\|}$$



- Se  $\nabla f^t B_k \nabla f > 0$  então a solução pode não estar na borda. Temos que olhar para o minimizador irrestrito de  $m(d)$ :

$$\frac{d}{dt} m(-t \nabla f) = -\|\nabla f\|^2 + t(\nabla f^t B_k \nabla f) = 0$$

$$\Rightarrow t^* = \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f} > 0.$$

Caso  $t^* < \frac{\Delta_k}{\|\nabla f\|}$  então  $t_k = t^*$ . Caso contrário,

$t_k = \frac{\Delta_k}{\|\nabla f\|}$ . Em resumo,

$$(*) \quad d^k = -t_k \nabla f(x^k) \quad \text{onde} \quad t_k = \begin{cases} \frac{\Delta_k}{\|\nabla f\|} & \text{se } \nabla f^t B_k \nabla f \leq 0 \\ \min \left\{ \frac{\Delta_k}{\|\nabla f\|}, \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f} \right\} & \text{c.c.} \end{cases}$$

Com o passo de Cauchy, há convergência:

Teorema: O passo de Cauchy satisfaz

$$m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f(x^k)\| \cdot \min \left\{ \Delta_k, \frac{\|\nabla f(x^k)\|}{\|B_k\|} \right\} \quad \left( \text{H3 com } c = \frac{1}{2} \right)$$

Prova: Como  $d^k = -t_k \nabla f$ , temos

$$\begin{aligned} m(0) - m(d^k) &= f(x^k) - f(x^k) - \nabla f^t d^k - \frac{1}{2} d^{k^t} B_k d^k \\ &= t_k \|\nabla f\|^2 - \frac{1}{2} t_k^2 \nabla f^t B_k \nabla f. \end{aligned}$$

CASO 1:  $\nabla f^t B_k \nabla f \leq 0$

De (\*),  $t_k = \frac{\Delta_k}{\|\nabla f\|}$  e  $m(0) - m(d^k) \geq t_k \|\nabla f\|^2 = \Delta_k \|\nabla f\|$ .

Em particular,  $m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f\| \Delta_k$ . (1)

CASO 2:  $\nabla f^t B_k \nabla f > 0$  e  $\frac{\Delta_k}{\|\nabla f\|} \leq \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$ .

Neste caso, (\*) fornece  $t_k = \frac{\Delta_k}{\|\nabla f\|} \leq \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$ , donde segue que  $t_k^2 \nabla f^t B_k \nabla f \leq t_k \|\nabla f\|^2 = \|\nabla f\| \Delta_k$ . Daí

$$m(0) - m(d^k) \geq \|\nabla f\| \Delta_k - \frac{1}{2} \|\nabla f\| \Delta_k = \frac{1}{2} \|\nabla f\| \Delta_k. \quad (2)$$


CASO 3:  $\nabla f^t B_k \nabla f > 0$  e  $\frac{\Delta_k}{\|\nabla f\|} > \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$ .

De (\*) vem  $t_k = \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$  e logo

$$m(0) - m(d^k) = \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f} - \frac{1}{2} \cdot \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f} = \frac{1}{2} \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f}.$$

Pela desigualdade de Cauchy-Schwartz, temos  
 $\nabla f^t(B_k \nabla f) \leq \|\nabla f\| \cdot \|B_k \nabla f\| \leq \|B_k\| \cdot \|\nabla f\|^2$ . Assim,

$$m(0) - m(d^k) \geq \frac{1}{2} \frac{\|\nabla f\|^4}{\|B_k\| \cdot \|\nabla f\|^2} = \frac{1}{2} \|\nabla f\| \cdot \frac{\|\nabla f\|}{\|B_k\|}. \quad (3)$$

Finalmente, de (1), (2) e (3) chegamos ao  
resultado 

Observações:

1) O passo de Cauchy, apesar de ter baixo custo computacional, fornece um método muito próximo à solução pois a direção  $d^k = -t_k \nabla f(x^k)$  é similar à do método do gradiente.

2) Note que a informação em  $B_k$  não é usada na direção (que é paralela à  $-\nabla f(x^k)$ ).  $B_k$  é usada apenas para escalar  $-\nabla f(x^k)$  (cálculo de  $t_k$ ). Essa deficiência fica evidente para  $B_k = \nabla^2 f(x^k)$ , pois o modelo com essa  $B_k$  e "d livre" remonta ao

método de Newton, que é muito mais rápido que o método do gradiente.

3) Portanto é razoável aproveitar  $B_k$  ao máximo, idealmente no estilo Newton / Quase-Newton.

O próximo método procura fazer isso!

2ª forma: método dogleg

Neste método, a solução aproximada  $d^k$  do modelo  $\min_d m(d)$  s.a.  $\|d\| \leq \Delta_k$  aproveita melhor  $B_k$ .

Ele se aplica a  $B_k$  definida positiva e simétrica (opções para tal  $B_k$  em aula anterior). Quando é possível

$B_k = \nabla^2 f(x^k)$ , o passo do método dogleg coincide com Newton caso a direção Newtoniana satisfaça

$$\|d\| \leq \Delta_k.$$

Dado o modelo ao redor de  $x^k$ , considere

os seguintes pontos:

- $x_u^k$ : minimizador **irrestrito** de  $m$  na direção  $-\nabla f(x^k)$ , isto é,

$$x_u^k = x^k - t^* \nabla f(x^k), \quad t^* = \underset{t}{\operatorname{argmin}} m(-t \nabla f(x^k)).$$

- $x_N^k$ : minimizador **irrestrito** de  $m$ , isto é,

$$x_N^k = x^k + d_N^*, \quad d_N^* = \underset{d}{\operatorname{argmin}} m(d).$$

Supondo  $B_k$  definida positiva, esses pontos estão bem definidos pois  $m(d)$  é uma quadrática estritamente convexa.


O método dogleg minimiza  $m(d)$  sobre a poligonal que liga  $x^k$ ,  $x_u^k$  e  $x_N^k$ , respeitando  $\|d\| \leq \Delta_k$ . Algumas situações:

$$1) \|x^k - x_N^k\| \leq \Delta_k$$


A direção será  $d^k = x_N^k - x^k$ .

Ou seja, o ponto dogleg é  $x_N^k$ .

Se  $B_k = \nabla^2 f(x^k)$ , este é o passo




de Newton.



$$2) \|x^k - x_v^k\| \leq \Delta_k < \|x^k - x_N^k\|$$

O ponto do leg  $x^k + d^k$  estará na borda, intermediário entre  $x_v^k$  e  $x_N^k$ .



$$3) \|x^k - x_v^k\| > \Delta_k$$

O ponto do leg  $x^k + d^k$  estará na borda, e coincide com o passo de Cauchy.


Outra situação pode ocorrer? **NÃO!**

↳ Teorema: (i)  $\|x^k - x_p\|$  cresce quando o ponto  $x_p$  sobre a poligonal vai de  $x^k$  a  $x_N^k$ .  
(a poligonal corta a borda no máximo 1 vez)  
(ii)  $m(x_p - x^k)$  é não decrescente ao longo

da poligonal.

(o fim de minimizar  $m$ , devemos caminhar de  $x^k$  a  $x_N^k$ . Neste sentido,  $x_N^k$  é o melhor ponto — de fato é aquele que vem da minimização sem  $\|d\| \leq \Delta_k$  com  $d$  livre)

\* Veja o Lema 5.40 do livro de Karas e Ribeiro ou o Lema 4.2 de Nocedal e Wright.



Dirções

$$d_v^k = x_v^k - x^k = -t^* \nabla f(x^k)$$

$$d_N^k = x_N^k - x^k \text{ (tipo Newton)}$$

$d^k$  (direção do leg)

Calculando  $d_v^k$ :

$$\min_t m(-t \nabla f(x^k))$$

$$0 = \frac{d}{dt} m(-t \nabla f(x^k)) = -\|\nabla f\|^2 + t^* \nabla f^T B_k \nabla f \Rightarrow t^* = \frac{\nabla f^T \nabla f}{\nabla f^T B_k \nabla f}$$



$$\Rightarrow d_v^k = - \left( \frac{\nabla f^k \nabla f}{\nabla f^k B_k \nabla f} \right) \nabla f$$

Calculando  $d_v^k$ :  $\min_d m(d)$

$$0 = \nabla m(d_v^k) = \nabla f + B_k d_v^k \Rightarrow B_k d_v^k = -\nabla f(x^k)$$


Algoritmo dog dog (para cálculo de  $d^k$ )

Entrada:  $x^k, \Delta_k > 0$

→ calcule  $d_v^k = - \left( \frac{\nabla f(x^k)^T \nabla f(x^k)}{\nabla f(x^k)^T B_k \nabla f(x^k)} \right) \nabla f(x^k)$

→ se  $\|d_v^k\| > \Delta_k$

$$d^k = - \frac{\Delta_k}{\|\nabla f(x^k)\|} \nabla f(x^k)$$




senão

→ resolva  $B_k d_v = -\nabla f(x^k)$ , obtendo  $d_v^k$

→ se  $\|d_v^k\| \leq \Delta_k$

$$d^k = d_v^k$$

senão




(por exemplo usando Cholesky)

→ calcule  $\alpha_k \in [0,1]$  tal que

$$\|d_v^k + \alpha_k(d_v^k - d_u^k)\| = \Delta_k$$

→  $d^k = d_v^k + \alpha_k(d_v^k - d_u^k)$



No último caso ( $\|x_u^k - x^k\| \leq \Delta_k < \|x_v^k - x^k\|$ ), a direção dogleg é combinação convexa das direções  $d_v^k$  e  $d_u^k$  (veja a figura (\*\*)):

$$d^k = d_v^k + \alpha_k(d_u^k - d_v^k) = (1 - \alpha_k)d_v^k + \alpha_k d_u^k, \quad \alpha_k \in [0,1]$$

Exercício: mostre que é possível calcular  $\alpha_k$  como raiz positiva de uma equação de 2º grau.


Vamos mostrar agora que o método de regiões de confiança com passo dogleg converge, mostrando que H3 é satisfeita.

Teorema: O passo dogleg satisfaz

$$m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f(x^k)\| \cdot \min \left\{ \Delta_k, \frac{\|\nabla f(x^k)\|}{\|B_k\|} \right\}.$$

Prova: Seja  $d_c^k$  a direção de Cauchy. Como mostramos,  
 $m(0) - m(d_c^k) \geq \frac{1}{2} \|\nabla f\| \cdot \min\{\Delta_k, \frac{\|\nabla f\|}{\|B_k\|}\}$ . Agora, como  
 $m(x - x^k)$  não cresce ao longo da poligonal saindo  
de  $x^k$  à  $x_n^k$  (comentário anterior), temos

$$m(d^k) = m(x_{\text{dogleg}} - x^k) \leq m(x_{\text{cauchy}} - x^k) = m(d_c^k).$$

Logo  $m(0) - m(d^k) \geq m(0) - m(d_c^k)$ , donde segue o  
resultado. 

### 3ª forma: gradientes conjugados de Steihaug

Gradientes conjugados (GC) é aplicado à minimiza-  
ção irrestrita de quadráticas (disciplina "Otimização I").

Aqui, GC é adaptado para lidar com a restrição

$\|d\| \leq \Delta_k$ . Este método é adequada a problemas

grandes. Veja o livro de Karas e Ribino para mais  
detalhes.