

Região de confiança - métodos específicos

No esquema geral, devemos calcular d^k solução aproximada do modelo

$$\min_d m(d) = f(x^k) + \nabla f(x^k)^t d + \frac{1}{2} d^t B_k d$$

s.a. $\|d\| \leq \Delta_k$.

Para garantir convergência, d^k deve satisfazer a hipótese H3 (veja anotações sobre convergência).

O objetivo é discutir diferentes formas de fazer isso.

1ª forma: passo de Cauchy

Suponhamos que $d^k = -t_k \nabla f(x^k)$, onde $t_k > 0$ é solução de $\min_t m(-t \nabla f(x^k))$. ($\|\cdot\|$ = norma Euclidiana)
s.a. $\|t \nabla f(x^k)\| \leq \Delta_k$


Resolvendo (omitindo x^k):

• Se $\nabla f^t B_k \nabla f \leq 0$ então o termo quadrático

$d^t B_k d = t^2 \nabla f^t B_k \nabla f \leq 0$ não influencia na minimização

ção, e a solução estará na borda:

$$\|t_k \nabla f\| = \Delta_k \Rightarrow t_k = \frac{\Delta_k}{\|\nabla f\|}$$



- Se $\nabla f^t B_k \nabla f > 0$ então a solução pode não estar na borda. Temos que olhar para o minimizador irrestrito de $m(d)$:

$$\frac{d}{dt} m(-t \nabla f) = -\|\nabla f\|^2 + t(\nabla f^t B_k \nabla f) = 0$$

$$\Rightarrow t^* = \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f} > 0.$$

Caso $t^* < \frac{\Delta_k}{\|\nabla f\|}$ então $t_k = t^*$. Caso contrário,

$t_k = \frac{\Delta_k}{\|\nabla f\|}$. Em resumo,

$$(*) \quad d^k = -t_k \nabla f(x^k) \quad \text{onde} \quad t_k = \begin{cases} \frac{\Delta_k}{\|\nabla f\|} & \text{se } \nabla f^t B_k \nabla f \leq 0 \\ \min \left\{ \frac{\Delta_k}{\|\nabla f\|}, \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f} \right\} & \text{c.c.} \end{cases}$$

Com o passo de Cauchy, há convergência:

Teorema: O passo de Cauchy satisfaz

$$m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f(x^k)\| \cdot \min \left\{ \Delta_k, \frac{\|\nabla f(x^k)\|}{\|B_k\|} \right\} \quad \left(\text{H3 com } c = \frac{1}{2} \right)$$

Prova: Como $d^k = -t_k \nabla f$, temos

$$\begin{aligned} m(0) - m(d^k) &= f(x^k) - f(x^k) - \nabla f^t d^k - \frac{1}{2} d^{k^t} B_k d^k \\ &= t_k \|\nabla f\|^2 - \frac{1}{2} t_k^2 \nabla f^t B_k \nabla f. \end{aligned}$$

CASO 1: $\nabla f^t B_k \nabla f \leq 0$

De (*), $t_k = \frac{\Delta_k}{\|\nabla f\|}$ e $m(0) - m(d^k) \geq t_k \|\nabla f\|^2 = \Delta_k \|\nabla f\|$.

Em particular, $m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f\| \Delta_k$. (1)

CASO 2: $\nabla f^t B_k \nabla f > 0$ e $\frac{\Delta_k}{\|\nabla f\|} \leq \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$.

Neste caso, (*) fornece $t_k = \frac{\Delta_k}{\|\nabla f\|} \leq \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$, donde segue que $t_k^2 \nabla f^t B_k \nabla f \leq t_k \|\nabla f\|^2 = \|\nabla f\| \Delta_k$. Daí

$$m(0) - m(d^k) \geq \|\nabla f\| \Delta_k - \frac{1}{2} \|\nabla f\| \Delta_k = \frac{1}{2} \|\nabla f\| \Delta_k. \quad (2)$$


CASO 3: $\nabla f^t B_k \nabla f > 0$ e $\frac{\Delta_k}{\|\nabla f\|} > \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$.

De (*) vem $t_k = \frac{\|\nabla f\|^2}{\nabla f^t B_k \nabla f}$ e logo

$$m(0) - m(d^k) = \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f} - \frac{1}{2} \cdot \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f} = \frac{1}{2} \frac{\|\nabla f\|^4}{\nabla f^t B_k \nabla f}.$$

Pela desigualdade de Cauchy-Schwartz, temos
 $\nabla f^t(B_k \nabla f) \leq \|\nabla f\| \cdot \|B_k \nabla f\| \leq \|B_k\| \cdot \|\nabla f\|^2$. Assim,

$$m(0) - m(d^k) \geq \frac{1}{2} \frac{\|\nabla f\|^4}{\|B_k\| \cdot \|\nabla f\|^2} = \frac{1}{2} \|\nabla f\| \cdot \frac{\|\nabla f\|}{\|B_k\|}. \quad (3)$$

Finalmente, de (1), (2) e (3) chegamos ao
resultado 

Observações:

1) O passo de Cauchy, apesar de ter baixo custo computacional, fornece um método muito próximo à solução pois a direção $d^k = -t_k \nabla f(x^k)$ é similar à do método do gradiente.

2) Note que a informação em B_k não é usada na direção (que é paralela à $-\nabla f(x^k)$). B_k é usada apenas para escalar $-\nabla f(x^k)$ (cálculo de t_k). Essa deficiência fica evidente para $B_k = \nabla^2 f(x^k)$, pois o modelo com essa B_k e "d livre" remonta ao

método de Newton, que é muito mais rápido que o método do gradiente.

3) Portanto é razoável aproveitar B_k ao máximo, idealmente no estilo Newton / Quase-Newton.

O próximo método procura fazer isso!

2ª forma: método dogleg

Neste método, a solução aproximada d^k do modelo $\min_d m(d)$ s.a. $\|d\| \leq \Delta_k$ aproveita melhor B_k .

Ele se aplica a B_k definida positiva e simétrica (opções para tal B_k em aula anterior). Quando é possível

$B_k = \nabla^2 f(x^k)$, o passo do método dogleg coincide com Newton caso a direção Newtoniana satisfaça

$\|d\| \leq \Delta_k$.

Dado o modelo ao redor de x^k , considere

os seguintes pontos:

- x_v^k : minimizador **irrestrito** de m na direção $-\nabla f(x^k)$, isto é,

$$x_v^k = x^k - t^* \nabla f(x^k), \quad t^* = \underset{t}{\operatorname{argmin}} m(-t \nabla f(x^k)).$$

- x_N^k : minimizador **irrestrito** de m , isto é,

$$x_N^k = x^k + d_N^*, \quad d_N^* = \underset{d}{\operatorname{argmin}} m(d).$$

Supondo B_k definida positiva, esses pontos estão bem definidos pois $m(d)$ é uma quadrática estritamente convexa.


O método dogleg minimiza $m(d)$ sobre a poligonal que liga x^k , x_v^k e x_N^k , respeitando $\|d\| \leq \Delta_k$. Algumas situações:

$$1) \|x^k - x_N^k\| \leq \Delta_k$$


A direção será $d^k = x_N^k - x^k$.

Ou seja, o ponto dogleg é x_N^k .

Se $B_k = \nabla^2 f(x^k)$, este é o passo




de Newton.



$$2) \|x^k - x_{v+1}^k\| \leq \Delta_k < \|x^k - x_N^k\|$$

O ponto do lado $x^k + d^k$ estará na borda, intermediário entre x_v^k e x_N^k .



$$3) \|x^k - x_{v+1}^k\| > \Delta_k$$

O ponto do lado $x^k + d^k$ estará na borda, e coincide com o passo de Cauchy.


Outra situação pode ocorrer? **NÃO!**

↳ Teorema: (i) $\|x_p - x^k\|$ cresce quando o ponto x_p sobre a poligonal vai de x^k a x_N^k .
(a poligonal corta a borda no máximo 1 vez)
(ii) $m(x_p - x^k)$ é não decrescente ao longo

da poligonal.

(o fim de minimizar m , devemos caminhar de x^k a x_N^k . Neste sentido, x_N^k é o melhor ponto — de fato é aquele que vem da minimização sem $\|d\| \leq \Delta_k$ com d livre)

* Veja o Lema 5.40 do livro de Karas e Ribeiro ou o Lema 4.2 de Nocedal e Wright.



Dirções

$$d_v^k = x_v^k - x^k = -t^* \nabla f(x^k)$$

$$d_N^k = x_N^k - x^k \text{ (tipo Newton)}$$

d^k (direção do leg)

Calculando d_v^k :

$$\min_t m(-t \nabla f(x^k))$$

$$0 = \frac{d}{dt} m(-t^* \nabla f(x^k)) = -\|\nabla f\|^2 + t^* \nabla f^T B_k \nabla f \Rightarrow t^* = \frac{\nabla f^T \nabla f}{\nabla f^T B_k \nabla f}$$

$$\Rightarrow d_v^k = - \left(\frac{\nabla f^k \nabla f}{\nabla f^k B_k \nabla f} \right) \nabla f$$

Calculando d_v^k : $\min_d m(d)$

$$0 = \nabla m(d_v^k) = \nabla f + B_k d_v^k \Rightarrow B_k d_v^k = -\nabla f(x^k)$$


Algoritmo dog dog (para cálculo de d^k)

Entrada: $x^k, \Delta_k > 0$

→ calcule $d_v^k = - \left(\frac{\nabla f(x^k)^T \nabla f(x^k)}{\nabla f(x^k)^T B_k \nabla f(x^k)} \right) \nabla f(x^k)$

→ se $\|d_v^k\| > \Delta_k$

$$d^k = - \frac{\Delta_k}{\|\nabla f(x^k)\|} \nabla f(x^k)$$




senão

→ resolva $B_k d_v = -\nabla f(x^k)$, obtendo d_v^k

→ se $\|d_v^k\| \leq \Delta_k$

$$d^k = d_v^k$$

senão




(por exemplo usando Cholesky)

→ calcule $\alpha_k \in [0,1]$ tal que

$$\|d_v^k + \alpha_k(d_v^k - d_u^k)\| = \Delta_k$$

→ $d^k = d_v^k + \alpha_k(d_v^k - d_u^k)$



No último caso ($\|x_u^k - x^k\| \leq \Delta_k < \|x_v^k - x^k\|$), a direção dog leg é combinação convexa das direções d_v^k e d_u^k (veja a figura (**)):

$$d^k = d_v^k + \alpha_k(d_u^k - d_v^k) = (1 - \alpha_k)d_v^k + \alpha_k d_u^k, \quad \alpha_k \in [0,1]$$

Exercício: mostre que é possível calcular α_k como raiz positiva de uma equação do 2º grau.


Vamos mostrar agora que o método de região de confiança com passo dog leg converge, mostrando que H3 é satisfeita.

Teorema: O passo dog leg satisfaz

$$m(0) - m(d^k) \geq \frac{1}{2} \|\nabla f(x^k)\| \cdot \min \left\{ \Delta_k, \frac{\|\nabla f(x^k)\|}{\|B_k\|} \right\}.$$

Prova: Seja d_c^k a direção de Cauchy. Como mostramos,
 $m(0) - m(d_c^k) \geq \frac{1}{2} \|\nabla f\| \cdot \min\{\Delta_k, \frac{\|\nabla f\|}{\|B_k\|}\}$. Agora, como
 $m(x - x^k)$ não cresce ao longo da poligonal saindo
 de x^k à x_n^k (comentário anterior), temos

$$m(d^k) = m(x_{\text{dogleg}} - x^k) \leq m(x_{\text{cauchy}} - x^k) = m(d_c^k).$$

Logo $m(0) - m(d^k) \geq m(0) - m(d_c^k)$, donde segue o
 resultado. 

3ª forma: gradientes conjugados de Steihaug

Gradientes conjugados (GC) é aplicado à minimiza-
 ção irrestrita de quadráticas (disciplina "Otimização I").

Aqui, GC é adaptado para lidar com a restrição

$\|d\| \leq \Delta_k$. Este método é adequada a problemas

grandes. Veja o livro de Karas e Ribino para mais
 detalhes.