

## Gradiente incremental

(1)

$$\min_{x \in \mathbb{R}^m} f(x) = \sum_{j=1}^m f_j(x).$$

- No nosso caso,  $m \gg 1$  e o cálculo de  $\nabla f$  fica caro.
- Ao invés de avaliar  $\nabla f$  (e consequentemente  $\nabla f_j, V_j$ ), avaliamos  $\nabla f_j$  para algum  $j$  por iterações (muito mais barato!)
- Vamos intuir o método do gradiente usando essa ideia de "gradientes incrementais".

• A cada iteração, escolhemos um  $i \in \mathcal{I}$   
damos um passo na direção  $-\nabla f_{i+1}(x^k, i)$ ,  
onde  $x^{k,i}$  é o ponto corrente.

↳  $i$  pode ser escolhido aleatoriamente  
em  $\{0, \dots, m-1\}$  desde que a escolha  
seja uniforme.

↳ podemos escolher um subconjunto  
pequeno  $\mathcal{I} \subset \{1, \dots, m\}$  e iterar  
na direção  $-\sum_{i \in \mathcal{I}} \nabla f_i(x^k)$  (descenso  
por blocos)

↳ para simplificar, vamos escolher índice 3  
por índice i (gradiente incremental)  
em ordem crescente 0, 1, ..., m-1.

Exemplo:  $f(x_1, x_2) = \underbrace{(x_1^2 + 2x_2)}_{f_1(x_1, x_2)} + \underbrace{(2x_2^2)}_{f_2(x_1, x_2)}$

Ponto inicial:  $x^0 = (2, 2)$ ,  $k=0$

Passo :  $t = 1/2$

Iteração gradiente tradicional:

(4)

$$x^{k+1} = x^k - t \nabla f(x^k) , \quad \nabla f(x) = \begin{bmatrix} 2x_1 \\ 4x_2 + 2 \end{bmatrix}$$

$$= (2, 2) - \frac{1}{2}(4, 10) = (0, -3)$$

$$\boxed{f(x^{k+1}) = 12}$$

Iteração gradiente incremental:

$$f(x) = f_1(x) + f_2(x) , \quad \nabla f_1 = \begin{bmatrix} 2x_1 \\ 2 \end{bmatrix} , \quad \nabla f_2 = \begin{bmatrix} 0 \\ 4x_2 \end{bmatrix}$$

15

$$\lambda^k = \lambda$$

$$x^{k,0} = x^0 = (2, 2)$$

$$\overbrace{x^{k,1}} = x^{k,0} - t \nabla f_1(x^{k,0}) \quad (i=0)$$

$$= (2, 2) - \frac{1}{2}(4, 2) = (0, 1)$$

$$\overbrace{x^{k,2}} = x^{k,1} - t \nabla f_2(x^{k,1}) \quad (i=1)$$

$$= (0, 1) - \frac{1}{2}(0, 4) = (0, -1)$$


$$x^{k+1} = x^{k,2} = (0, -1).$$

$$f(x^{k+1}) = f(0, -1) = 0$$

[6]


- As iterações incremental reduzem mais  $f$  e com custo igual (cálculo de  $\nabla f_1$  e  $\nabla f_2$ )

minim  
de  $f$



# Método do gradiente incremental

17



- O laço que percorre todos os gradientes  $\nabla f_{i+1}, i=0, \dots, m-1$ , é chamado de ciclo ou época. 18
- Note que  $x^{k,i+1}$  é o resultado de um passo a partir de  $x^{k,i}$ . Essa é a diferença com o gradiente tradicional.  
↳ visa acelerar a convergência a um custo não maior.
- Note que  $t_k$  é o mesmo p/ cada ciclo.

- versões com  $i$  escolhido aleatoriamente.  
e por blocos seguem o mesmo esquema.
- o critério de parada tipo " $\nabla f(x^k) \approx 0$ " é mais complicado, pois não calculamos  $\nabla f$  inteiro. Na prática (em particular no aprendizado de máquina), paramos com número fixo de iterações externas.

19

- Sobre da solução, gradiente incremental  $\nabla f$  costuma ser muito efetivo, muito mais que gradiente tradicional!
- Porém, perto da solução não! Isso porque próximo à solução, os passos devem ser mais refinados, e logo usar  $\nabla f$  é mais efetivo.
- Assim, gradiente incremental é útil quando não precisamos de alta precisão (caso do aprendizado de máquina).

# Convergência do método do gradiente

11

## incremental para funções convexas

- $f_j$  convexa,  $j=1, \dots, m$ .

Neste caso, temos que

$$f_j(y) \geq f_j(x) + \nabla f_j(x)^T (y - x), \forall y, x.$$

- $\{x^k\}$  sequência gerada pelo método.

Hipótese: H1)  $\exists L > 0$  tal que  $L \geq \|\nabla f_{j+1}(x^{k,i})\|$

$\forall i, k$  (compara com subgradiente)

Lema: Suponha  $f_j$  convexa  $\forall j \in H_1$ . . . (12)

Para todo  $y \in \mathbb{R}^m$  temos

$$\|x^{k+1} - y\|^2 \leq \|x^k - y\|^2 - 2t_k(f(x^k) - f(y)) + t_k^2 m^2 L^2.$$

Prova: Para cada  $i = 0, \dots, m-1$ , temos

$$\|x^{k,i+1} - y\|^2 = \|x^{k,i} - t_k \nabla f_{i+1}(x^{k,i}) - y\|^2$$

$$= \|x^{k,i} - y\|^2 - 2t_k \nabla f_{i+1}(x^{k,i})^T (x^{k,i} - y) + t_k^2 \|\nabla f_{i+1}(x^{k,i})\|^2$$

$$\leq \|x^{k,i} - y\|^2 - 2t_k (f_{i+1}(x^{k,i}) - f_{i+1}(y)) + t_k^2 L^2$$

$f_{i+1}$  convexa,  
 $H_1$

Somando para  $i=0, \dots, m-1$  e cancelando 13 termos de ambos os lados das desigualdades, obtemos (lembrando que  $x^{k,0} = x^k$  e  $x^{k,m} = x^{k+1}$ )

$$\|x^{k+1} - y\|^2 \leq \|x^k - y\|^2 - 2t_k \sum_{i=0}^{m-1} (f_{i+1}(x^{k,i}) - f_{i+1}(y)) + t_k^2 m L^2$$

Como  $\sum_{i=0}^{m-1} f_{i+1}(z) = f(z)$ , temos

$$\|x^{k+1} - y\|^2 \leq \|x^k - y\|^2 - 2t_k [f(x^k) - f(y) + \sum_{i=0}^{m-1} (f_{i+1}(x^{k,i}) - f_{i+1}(y))]$$

$$-f_{i+1}(x^k)\Big) \Big] + t_k^2 m L^2.$$

[14]

Como  $f_{i+1}$  é convexa, temos

$$f_{i+1}(x^{k,i}) - f_{i+1}(x^k) \geq \nabla f_{i+1}(x^k)^T (x^{k,i} - x^k).$$

Dai,

$$\|x^{k+1} - y\|^2 \leq \|x^k - y\|^2 - 2t_k (f(x^k) - f(y))$$

$$+ 2t_k \sum_{i=0}^{m-1} -\nabla f_{i+1}(x^k)^T (x^{k,i} - x^k) + t_k^2 m L^2$$

$$\leq \|\nabla f_{i+1}(x^k)\| \cdot \|x^{k,i} - x^k\|$$

$$\begin{aligned}
 & \leq \|x^k - y\|^2 - 2t_k (f(x^k) - f(y)) \\
 & + 2t_k L \sum_{i=0}^{m-1} \|x^{k,i} - x^k\| + t_k^2 m L^2.
 \end{aligned} \tag{15}$$

Agora, vemos que

- $\|x^{k,0} - x^k\| = \|x^k - x^k\| = 0$
- $\|x^{k,1} - x^k\| = \|x^{k,0} - t_k \nabla f_1(x^{k,0}) - x^k\|$   
 $\leq \|x^{k,0} - x^k\| + t_k \|\nabla f_1(x^{k,0})\| \leq t_k L$

$$\begin{aligned} \|\boldsymbol{x}^{k,2} - \boldsymbol{x}^k\| &= \|\boldsymbol{x}^{k,1} - t_k \nabla f_2(\boldsymbol{x}^{k,1}) - \boldsymbol{x}^k\| \\ &\leq \|\boldsymbol{x}^{k,1} - \boldsymbol{x}^k\| + t_k \|\nabla f_2(\boldsymbol{x}^{k,1})\| \leq 2t_k L. \end{aligned} \quad [16]$$

Em geral,

$$\|\boldsymbol{x}^{k,i} - \boldsymbol{x}^k\| \leq i t_k L, \quad i = 0, \dots, m-1$$

Usando estas desigualdades obtemos

$$\begin{aligned} \|\boldsymbol{x}^{k+1} - \boldsymbol{y}\|^2 &\leq \|\boldsymbol{x}^k - \boldsymbol{y}\|^2 - 2t_k (f(\boldsymbol{x}^k) - f(\boldsymbol{y})) \\ &\quad + 2t_k^2 L^2 \sum_{i=0}^{m-1} i + t_k^2 m L^2. \end{aligned}$$

Como  $\sum_{i=0}^{m-1} i = \frac{m(m-1)}{2}$ , obtemos . (17)

$$\|x^{k+1} - y\|^2 \leq \|x^k - y\|^2 - 2t_k(f(x^k) - f(y)) + t_k^2 m^2 L^2,$$

Como queríamos provar. 

Este resultado é parecido com o obtido para o método do subgradiente (verifique).

Aliás, é possível definir o método do subgradiente incremental (lista exercícios).

Como no método do subgradiente, é comum (18) considerar os passos nos seguintes casos:

1) passo constante:  $t_k = t > 0, \forall k$ .

2) passo decrescente:  $\{t_k\}$  tal que

$$t_k \rightarrow 0^+, \sum_{k=0}^{\infty} t_k^2 < \infty, \sum_{k=0}^{\infty} t_k = \infty.$$

No aprendizado de máquina, ambas as ideias são empregadas. Note que o lema indica que para  $t \ll 1$ , o método funcionará.

Teorema: Suponha  $f_j$  convexa  $\forall j$ , H1 válida (19) e que  $f(x) = \sum_{j=1}^m f_j(x)$  admira minimizadora  $x^*$ . Seja  $\{t_k\}$  tal que

$$t \rightarrow 0^+, \quad \sum_{k=0}^{\infty} t_k^2 < \infty \quad \text{e} \quad \sum_{k=0}^{\infty} t_k = \infty.$$

Então

$$f_\infty = \liminf_{k \rightarrow \infty} f(x^k) = f^*,$$

onde  $f^* = f(x^*) = \min_x f(x) (> -\infty)$ .

Prova: Pelo Lema (com  $y = x^*$ ), temos (20)

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - 2t_k(f(x^k) - f^*) + t_k^2 m^2 L^2$$

$$\begin{aligned} &\leq \|x^{k-1} - x^*\|^2 - 2t_{k-1}(f(x^{k-1}) - f^*) + t_{k-1}^2 m^2 L^2 \\ &\quad - 2t_k(f(x^k) - f^*) + t_k^2 m^2 L^2 \end{aligned}$$

$$\leq \dots \leq \|x^0 - x^*\|^2 - 2 \sum_{i=0}^k t_i(f(x^i) - f^*) + m^2 L^2 \sum_{i=0}^k t_i^2$$

$$\Rightarrow \left( 2 \sum_{i=0}^k t_i \right) (f_k - f^*) \leq 2 \sum_{i=0}^k t_i (f(x^i) - f^*)$$

$$\leq \|x^0 - x^*\|^2 + m^2 L^2 \sum_{i=0}^K t_i^2 , \quad (2.1)$$

onde  $f_K = \min_{0 \leq i \leq K} f(x^i)$ . Daí,

$$f_K - f^* \leq \frac{\|x^0 - x^*\|^2 + m^2 L^2 \sum_{i=0}^K t_i^2}{2 \sum_{i=0}^K t_i} .$$

O resultado segue das condições sobre  $\{t_k\}$   
fazendo  $K \rightarrow \infty$

Pode-se provar resultado parecido com (22) o método de subgradiêntes para  $t_k = t$  constante, usando o lema anterior.  
(exercício).