

Método do gradiente estocástico

(1)

Problema: $\min f(x), \quad f: \mathbb{R}^n \rightarrow \mathbb{R}$ convexa

Não temos acesso à $\nabla f(x)$ (por exemplo, porque é caro computar).

Iteração: $x^{k+1} = x^k - t_k g^k, \quad t_k > 0$


• g^k é uma estimativa aleatória de $\nabla f(x^k)$ (passo)

• Assim, x^{k+1} depende da amostra de pontos.

anteriores (na verdade, está condicionado (2 apenas à escolha de x^k e g^k)

- ponto inicial x^0 é determinístico (fornecido pelo usuário); x^k , $k \geq 1$, aleatórios.

Método do gradiente estocástico



Como deve ser a escolha de g^* ? B

$$H1) E(g^* | x^*) = \nabla f(x^*)$$

(a rigor, deveria escrever G^* , mas vou manter g^* para refletir a escolha no método)

Essa hipótese diz que, em média, g^* deve ser o gradiente $\nabla f(x^*)$, mas não necessariamente $g^* = \nabla f(x^*)$.

H1 é conhecida como "escolha sem viés".

Note que a esperança em H1 é condicionada¹⁴ à escolha $X = x^*$ (corrente com gradiente clássico, onde $\hat{g}^* = \nabla f(x^*)$ só depende de x^*).

Hipótese Técnica:

H2) Existe uma constante $L > 0$ tal que

$$E(\|g^*\|^2 | x^*) \leq L^2.$$

(compare com os métodos do gradiente incremental e do subgradiente).

Exemplo: $f(x) = \frac{1}{m} \sum_{j=1}^m f_j(x)$, f_j convexa [5]

Considere o seguinte estimador para g^* ,
dado x^* :

"escolha $i_k \in \{1, \dots, m\}$ uniformemente
e tome $g^* = \nabla f_{i_k}(x^*)$ ".

Qual a esperança de g^* dado x^* ?

$$E(g^k | x^k) = \sum_{i=1}^m \nabla f_i(x^k) \cdot P(i) \quad (6)$$

prob. escolha
 de i

$$= \sum_{i=1}^m \nabla f_i(x^k) \frac{1}{m} = \frac{1}{m} \sum_{i=1}^m \nabla f_i(x^k)$$

$$= \nabla f(x^k).$$

Note que é importante que a escolha de i_k seja uniforme, de modo que $P(i) = \frac{1}{m}, \forall i.$


Este exemplo indica uma escolha possível
simples e sem riscos para nosso problema
de interesse! (7)

Com esta escolha, o método de gradiente
estocástico assemelha-se ao gradiente incrementa-
tal, com a diferença que i é escolhido
aleatoriamente, t_k pode ser diferente a cada
subiteração, e não há garantia da escolha
de todos os gradientes ∇f_i como no ciclo
do gradiente incremental.

Quando obrigamos a escolha de todos os L gradientes, o ciclo é chamado época.

Desta forma podemos dividir as iterações no nosso caso:

$$f(x) = \frac{1}{m} \sum_{j=1}^m f_j(x)$$



Obs:

19

- 1) note que há um passo para cada subiteração
- 2) se $t_{k,p(j)} = t > 0$ cte $\forall k, j$, então recainos no gradiente incremental com passo constante, com a diferença que i é aleatório.
- 3) Na época, todos ∇f_i são escolhidos.
- 4) Geralmente é assim que são as implementações
- 5) Porém, escolher todos ∇f_i é várias ???

Outra forma de estimar \hat{g}^k é fazer (10)

$$\hat{g}^k = \frac{1}{|S_k|} \sum_{j \in S_k} \nabla f_j(x^k),$$

onde $S_k \subset \{1, \dots, m\}$, $|S_k| \ll m$. S_k :
"mini-batch"
"mini-lote"

É importante que o mini-lote seja escolhido de maneira uniforme.

Uma maneira de proceder:

(11)

- 1) Temos $|S| \ll m$ o tamanho dos mini-lotes
(vamos supor que todos eles têm mesmo tamanho)
 - 2) Divida os dados de treinamento em m_B mini-lotes S_1, \dots, S_{m_B} (supor $m_B = \frac{m}{|S|} \in \mathbb{N}$).
 - 3) Escolha um mini-lote S_{i_k} onde
 i_k é escolhido uniformemente em $1, \dots, m_B$.
- Note que $E(g^k | x^k) = \sum_{i=1}^{m_B} \left(\frac{1}{|S|} \sum_{j \in S_i} \nabla f_j(x^k) \right) P(i)$

$$P(i) = \frac{1}{m_B} = \sum_{i=1}^{m_B} \left(\frac{m_B}{m} \sum_{j \in S_i} \nabla f_j(x^*) \right) \frac{1}{m_B} \quad (12)$$

$$= \frac{m_B}{m} \cdot \frac{1}{m_B} \sum_{j=1}^m \nabla f_j(x^*) = \nabla f(x^*)$$

(não há viés).

Note que aqui a época consiste em m_B escolhas de mini-lotes.

Uma outra maneira de implementar é a ⁽¹³⁾ seguinte (usada na prática):

- 1) temos $151 \ll m$ o tamanho dos mini-lotes
(vamos supor que todos eles têm mesmo tamanho);
- 2) a cada início de época, embaralhe os dados de treinamento;
- 3) divida os dados embaralhados em pedaços consecutivos de tamanho 151;

4) percorra sequencialmente todos os mini-lotes gerados. [14]

Isto evita viés ??? ...

De qualquer forma, valem as observações:

1) $|S| = m$ (1 lote) corresponde ao método de gradiente, pois calculamos $Df(x^k)$ inteiro por iteração;

- 2) $|S| = 1$ corresponde ao método do gradiente estocástico enunciado anteriormente (15)
- 3) É imperativo $|S| \ll m$ (iteração barata), mas pode ser interessante $|S| > 1$ pois usar > 1 gradiente ∇f_j fornece uma iteração mais eficaz.
- ↳ o balanço de $|S|$ é empírico!

Escolha dos passos (variantes do SG). [16]

- Método do gradiente estocástico "básico"
(SGD)

$$t_{k,ij} = \eta > 0 \quad \text{ete.}$$

≠ da ideia
original de
SG (1951)

- Adagrad (2011)

$$t_{k,ij} = \frac{\eta}{\sqrt{G_{k,ij} + \epsilon}}, \quad \eta > 0, \quad \epsilon \in (0,1) \text{ parâmetros,}$$

$$G_{k,ij} = \sum_{\tilde{k} \leq k, \tilde{i}, \tilde{j}} \|\tilde{g}_{\tilde{k},\tilde{i}j}\|^2.$$

Ideia: diminuir τ à medida que o (17)
método avança, inversamente proporcio-
nal ao acúmulo das normas dos
gradientes escolhidos.

(Lembra a ideia de passo decrescente
nos métodos do gradiente incremental
e de subgradientes).

- Passos com "momento".

18

Imagine que um corpo viaje de x^{k-1} até x^k com uma velocidade v^k . No ponto x^k , o corpo não fará uma "virada busca" pois há uma tendência a permanecer na direção $x^k - x^{k-1}$ (momento linear = massa $\times v$)

Por outro lado, a iteração $x^{k+1} = x^k - t g^k$ representa uma "virada busca" na direção $-g^k$.

Métodos com momento buscam incorporar a ideia física na direção de busca.

A ideia é trocar g^* por um "vetor velocidade", que combina g^* com a velocidade anterior:

$$x^{k+1} = x^k - t_k v^k \quad \text{onde}$$

$$v^k = \beta v^{k-1} + (1-\beta) g^k \quad (\beta \in [0,1] \text{ parâmetro})$$

Iniciamos a velocidade nula $v^{-1} = 0$.

• SGD com momento (1999)

(20)

$$t_{k,i,j} = \eta > 0 \text{ é } t_k,$$

$$\chi^{k,j+1} = \chi^{k,j} - \eta v^{k,j} \text{ onde}$$

$$v^{k,j} = \beta v^{k,j-1} + (1-\beta) g^{k,i_j}$$

, $\beta \in [0,1]$
parâmetro

• RMSProp (2012?)

Melhoramento do Adagrad.

- AdaDelta (2012)

L21

Outro melhoramento do Adagrad.

- Adam (2014/15)

Combina passo tipo Adagrad e momento

Obs: todas variantes podem implementar mini-lotes.