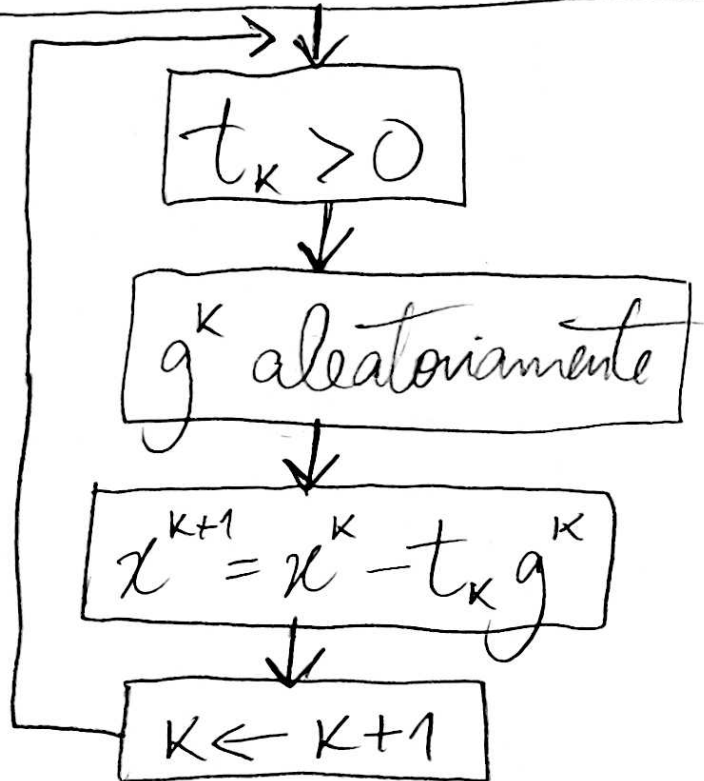


# Convergência do método do gradiente estocástico (1)

Dado  $x^0 \in \mathbb{R}^m$ ,  $k \leftarrow 0$



Problema:  $\min_x f(x)$

HIPÓTESES.

$$H1) E(g^k | x^k) = \nabla f(x^k) \\ (\text{sem vies})$$

$$H2) \exists L > 0 \text{ tal que} \\ E(\|g^k\|^2 | x^k) \leq L^2, \forall k.$$

Sequência gerada:  
 $\{x^k\}$ .

Passo decrescente:

$$(1) \ t_k \rightarrow 0^+, \quad \sum_{k=0}^{\infty} t_k = \infty, \quad \sum_{k=0}^{\infty} t_k^2 < \infty.$$

Teorema: Suponha  $f$  convexa,  $H1, H2$  válidas e que  $f$  admita minimizador  $x^*$ . Seja  $\{t_k\}$  como em (1). Então

$$\lim_{k \rightarrow \infty} E(f_k) = f^*,$$

onde  $f_k = \min_{0 \leq j \leq k} f(x^j)$  e  $f^* = \min_x f(x) = f(x^*)$ .

Prova: Para cada  $k \geq 0$  temos (3)

$$\begin{aligned} E(\|x^{k+1} - x^*\|^2 | x^k) &= E(\|x^k - t_k g^k - x^*\|^2 | x^k) \\ &= E(\|x^k - x^*\|^2 - 2t_k (g^k)^t (x^k - x^*) + t_k^2 \|g^k\|^2 | x^k) \\ &= E(\|x^k - x^*\|^2 | x^k) - 2t_k E((g^k)^t (x^k - x^*) | x^k) \\ &\quad + t_k^2 E(\|g^k\|^2 | x^k) \end{aligned}$$

Note que  $E(\|x^k - x^*\|^2 | x^k) = \|x^k - x^*\|^2$  visto que, dado  $x^k$ ,  $\|x^k - x^*\|^2$  fica determinado.

[4] Também,  $E((g^k)^t(x^k - x^*) | x^k) = E(\sum g_i^k(x_i^k - x_i^*) | x^k)$   
 $= \sum E(\underbrace{g_i^k(x_i^k - x_i^*)}_{\text{cte em } x^k} | x^k) = \sum E(g_i^k | x^k)(x_i^k - x_i^*)$

$$= E(g^k | x^k)^t (x^k - x^*).$$

Assim,

$$E(\|x^{k+1} - x^*\|^2 | x^k) = \|x^k - x^*\|^2 - 2t_k E(g^k | x^k)^t (x^k - x^*) + t_k^2 E(\|g^k\|^2 | x^k)$$

Relas hipóteses  $H1$  e  $H2$ , obtemos

$$E(\|x^{k+1} - x^*\|^2 | x^k) \leq \|x^k - x^*\|^2 - 2t_k [\nabla f(x^k)^t (x^k - x^*)] + t_k^2 L^2, \quad (5)$$

$f$  convexa

$$\leq \|x^k - x^*\|^2 - 2t_k (f(x^k) - f^*) + t_k^2 L^2.$$

Tomando a esperança em ambos os lados da desigualdade e lembrando que  $E(E(w|z)) = E(w)$  e que  $w \leq z \Rightarrow E(w) \leq E(z)$ , obtemos

$$E(\|x^{k+1} - x^*\|^2) \leq E(\|x^k - x^*\|^2) - 2t_k (E(f(x^k)) -$$

$$-f^*) + t_k^2 L^2.$$

6

Aplicando essa desigualdade sucessivas vezes,

$$E(\|x^{k+1} - x^*\|^2) \leq E(\|x^0 - x^*\|^2) - 2 \sum_{j=0}^k t_j (E(f(x^j))$$

$$- f^*) + L^2 \sum_{j=0}^k t_j^2$$

$$\Rightarrow \sum_{j=0}^k t_j (E(f(x^j)) - f^*) \leq \frac{1}{2} \left[ E(\|x^0 - x^*\|^2) + L^2 \sum_{j=0}^k t_j^2 \right].$$

Agora, usando o fato  $E(\min\{w, z\}) \leq \min\{E(w), E(z)\}$ , temos

[7]

$$E(f_k) = E\left(\min_{0 \leq j \leq k} f(x^j)\right) \leq \min_{0 \leq j \leq k} E(f(x^j)),$$

e logo

$$0 \leq E(f_k) - f^* \leq \frac{\|x^0 - x^*\|^2 + L^2 \sum_{j=0}^k t_j^2}{2 \sum_{j=0}^k t_j}$$

(note que  $E(\|x^0 - x^*\|^2) = \|x^0 - x^*\|^2$  pois  $x^0$  e

$x^*$  são determinísticos). Fazendo  $k \rightarrow \infty$  (2)  
obtemos  $\lim_{k \rightarrow \infty} E(f_k) = f^*$  das hipóteses sobre  
 $\{t_k\}$ . ▣

---

Obs: compare com a prova de convergência  
do método do gradiente incremental.

---

Passo constante  $t_k = t, \forall k$ : assim como no  
gradiente incremental, é possível provar  
convergência do método do gradiente



estocástico para funções convexas e passo  $L$  constante (o SG "básico" usa  $t_k = \text{cte}$  na prática).

Vamos nos inspirar nas provas do gradiente estocástico para passo decrescente e do subgradiente para passo constante.

---

Seguindo a prova anterior, note que

$$E(\|x^{k+1} - x^*\|^2) \leq E(\|x^k - x^*\|^2) - 2t_k(E(f(x^k)) - f^*) + t_k^2 L^2 \quad (2)$$

permanece válido independentemente da escolha de  $t_k$ . Essa desigualdade é uma versão do lema do método do subgradiente com esperanças (compare!). (10)

Seguindo a prova de convergência do subgradiente para o caso  $f^* > -\infty$  (estamos supondo aqui que  $f$  admite minimizadores), suponha

que

$$\liminf_{k \rightarrow \infty} E(f(x^k)) > f^* + \frac{tL^2}{2} + 2\varepsilon, \quad (3),$$

para algum  $\varepsilon > 0$ , Assim,  $t_k = t > 0, \forall k$ . (11)

Também, para todo  $k \gg 1$  temos

$$E(f(x^k)) \geq \liminf_{k \rightarrow \infty} E(f(x^k)) - \varepsilon. \quad (4)$$

Tomando (3) e (4) obtemos, para um certo  $k_0$ ,

$$E(f(x^k)) - f^* \geq \frac{tL^2}{2} + \varepsilon, \quad \forall k \geq k_0.$$

Assim, da inequação (2) com  $t_k = t$  temos

$$\begin{aligned} E(\|x^{k+1} - x^*\|^2) &\leq E(\|x^k - x^*\|^2) - 2t \left( \frac{tL^2}{2} + \varepsilon \right) + t^2 L^2 \\ &= E(\|x^k - x^*\|^2) - 2t\varepsilon, \quad \forall k \geq k_0. \end{aligned}$$

Aplicando essa desigualdade sucessivas vezes  
obtemos

$$E(\|x^{k+1} - x^*\|^2) \leq E(\|x^{k_0} - x^*\|^2) - 2(k+1-k_0)t\varepsilon.$$

Tomando  $k \gg k_0$  obtemos uma contradição  
pois  $-2(k+1-k_0)t\varepsilon \rightarrow -\infty$  e  $E(W) \geq 0$   
quando  $W \geq 0$ .

A contradição da suposição (3), isto é, 13  
que  $\exists \varepsilon > 0$  tal que

$$\liminf_{K \rightarrow \infty} E(f(x^K)) > f^* + \frac{tL^2}{2} + 2\varepsilon.$$

Em outras palavras, vale

$$\lim_{K \rightarrow \infty} E(f_K) - f^* \leq \frac{tL^2}{2}.$$

Compare com o resultado do método do subgradiente: só há garantia de chegar próximo do valor ótimo !!!

Isso demonstra o seguinte teorema: (14)

Teorema: Suponha  $f$  convexa,  $H1, H2$  válidas  
e que  $f$  admita minimizador  $x^*$ .

Suponha ainda que  $t_k = t > 0, \forall k$ .

Então

$$\lim_{k \rightarrow \infty} E(f_k) \leq f^* + \frac{tL^2}{2},$$

onde  $f_k = \min_{0 \leq j \leq k} f(x^j)$  e  $f^* = \min_x f(x) = f(x^*)$ .