

# Treinamento de redes neurais

(1)

Problema:  $\min_{w, b} R_m(w, b) = \frac{1}{m} \sum_{i=1}^m \ell(h(x_i; w, b); y_i)$

onde

- $\ell$  é a função de perda, que mede o erro na classificação do dado  $(x_i, y_i)$ .

↳ p.ex.,  $\ell(h, y) = \frac{1}{2} \|h - y\|^2$ ;

$$\ell(h, y) = \log(1 + e^{-h^T y}).$$

- $h$  é a função de predição, cuja imagem é

a resposta dada à entrada  $x$ .

(2)

- $h$  será composta de uma aplicação afim com uma função não linear  $a$  (função de ativação):

$$h(x; w, b) = a(wx + b).$$


Um exemplo de função de ativação é a sigmoide:  $a(z) = 1 / (1 + e^{-z})$ .

Notação:  $a(v) = \begin{bmatrix} a(v_1) \\ \vdots \\ a(v_m) \end{bmatrix}$ ,  $v \in \mathbb{R}^m$ .

**EX:**  $\min_{w,b} R_m(w,b) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} \|a(wx_i + b) - y_i\|^2$  (3)

Queremos aplicar gradiente estocástico, logo precisamos de avaliar, dados  $w, b$ , os termos da soma e seus gradientes em relação a  $(w, b)$ .

Lembre-se que  $h(x; w, b) = a(wx + b)$  é representado em um grafo, como aplicação sucessivas de funções:  $h(x) = f_L(f_{L-1}(\dots f_1(x) \dots))$ , onde cada  $f_i$  é da



camadas (layers)

feed forward

back propagation

forma  $a(Wx+b)$ .

(5)

Feedforward (avaliar  $R_m(w, b)$ )

Para cada  $i \in \{1, \dots, m\}$ , escrevemos o termo  $C = \frac{1}{2} \|a(Wx_i + b) - y_i\|^2$  como

$$C = \frac{1}{2} \|a^{[L]} - y\|^2 \quad (\text{omitimos } i)$$

onde  $a^{[L]}$  é a saída da rede neural.

Ele é obtido propagando a entrada  $x$  pela rede ( $W$  e  $b$  estão fixados):


$$a^{[1]} = x$$

$$a^{[2]} = a(w^{[2]} a^{[1]} + b^{[2]})$$

$$a^{[3]} = a(w^{[3]} a^{[2]} + b^{[3]})$$

⋮

$$a^{[L]} = a(w^{[L]} a^{[L-1]} + b^{[L]})$$




Em geral,

- $a^{[1]} = x$

- $a^{[l]} = a(w^{[l]} a^{[l-1]} + b^{[l]})$ ,  $l = 2, \dots, L$ .

- $C = \frac{1}{2} \|a^{[L]} - y\|^2$ .


Notação:  $w^{[l]}$ ,  $b^{[l]}$  são os pesos e vieses dos neurônios na camada  $l$ . Note que a camada de entrada não possui  $w$  e  $b$ ...




entrada  
( $x \in \mathbb{R}^2$ )

camada 2  
( $a^{[2]} \in \mathbb{R}^3$ )

$w_{jk}^{[l]}$  : peso associado  
ao neurônio  $j$   
da camada  $l$ ,  
fluxo do neurô-  
nio  $k$  da cama-  
da anterior

neurônio  recebe o fluxo  $x$ , pondera com  
o vetor  $w_1^{[2]} \in \mathbb{R}^2$ , adiciona o vies  $b_1^{[2]}$   
e passa o fluxo aplicando a ativação  $\sigma$ .





$$a_1^{[2]} = a(w_1^{[2]T} a^{[1]} + b_1^{[2]}).$$

$$a^{[1]} = x$$

Em geral, 
$$a_j^{[l]} = a\left(\sum_k w_{jk}^{[l]} a_k^{[l-1]} + b_j^{[l]}\right)$$

é a saída do neurônio  $j$  da camada  $l$ . Escrevendo em termos de matrizes,

$$a^{[l]} = a(W^{[l]} a^{[l-1]} + b^{[l]}), \text{ onde } \quad (10)$$

$W^{[l]}$  é matriz  $n_l \times n_{l-1}$  e  $b^{[l]} \in \mathbb{R}^{n_l}$ ,

$n_l, n_{l-1}$  número de neurônios nas camadas  $l$  e  $l-1$ , respectivamente.


Exemplo: calcular  $R_2(w, b)$  com 2 dados

$(x_1, y_1) = (1, 1)$  e  $(x_2, y_2) = (2, 0)$ , no

"ponto"  $W^{[2]} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ ,  $W^{[3]} = \begin{bmatrix} 2 & 3 \end{bmatrix}$ ,  $b^{[2]} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$ ,

$b^{[3]} = [1]$ , relativos à rede

(11)




(obs:  $(w, b)$  representa as matrizes  $W^{[l]}$ ,  $b^{[l]}$ , por exemplo, empilhando as colunas em sequência).

Considere a função de ativação sigmoid  $a(z) = 1/(1+e^{-z})$  em todos os neurônios.

Para o dado  $(x_1, y_1) = (1, 1)$ :

(12)


- $a^{[1]} = x_1 = [1]$



- $a^{[2]} = a(w^{[2]} a^{[1]} + b^{[2]})$

$$= a\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix} [1] + \begin{bmatrix} -1 \\ 2 \end{bmatrix}\right) = a\left(\begin{bmatrix} 0 \\ 3 \end{bmatrix}\right)$$

$$= \begin{bmatrix} \frac{1}{1+e^0} \\ \frac{1}{1+e^3} \end{bmatrix} \approx \begin{bmatrix} 0,5 \\ -0,1398 \end{bmatrix}$$




- $a^{[3]} = a(w^{[3]} a^{[2]} + b^{[3]})$

13

$$= a\left([2 \ 3] \begin{bmatrix} 0,5 \\ -0,1398 \end{bmatrix} + [1]\right) = a(1,5807)$$

$$\approx [-0,3033]$$



- $C_1 = \frac{1}{2} |a^{[3]} - y_1|^2 \approx 0,8493$

Para o dado  $(x_2, y_2) = (2, 0)$ :

(14)

Faça as contas e conclua que  $C_2 \approx 0,0969$ .  
(exercício) - Assim

$$R_2(w, b) \approx \frac{1}{2} (0,8493 + 0,0969) \approx 0,4731$$

Obs: note que ao avaliar  $C_i = \frac{1}{2} \|a(x_i; w, b) - y_i\|^2$ , computamos  $a^{[l]}$ ,  $1 \leq l \leq L$ , e

$$z^{[l]} = w^{[l]} a^{[l-1]} + b^{[l]}, \quad 2 \leq l \leq L.$$

## Back propagation (avaliar $\nabla R_m(w, b)$ )

15

No método do gradiente estocástico devemos avaliar um ou mais (poucos) gradientes de termos

$$C = C_i = \frac{1}{2} \|a(wx_i + b) - y_i\|^2$$

em relação a  $(w, b)$ . Vamos omitir o "i" do dado. Precisamos computar as parciais

$$\frac{\partial C}{\partial w_{jk}^{[l]}} \text{ e } \frac{\partial C}{\partial b_j^{[l]}}, \forall j, k, 2 \leq l \leq L.$$

Seja  $C = \frac{1}{2} \|a^{[L]} - y\|^2$ ,  $a^{[L]}$  composição de 16  
funções, aplicamos a regra da cadeia.  
As quantidades

$$\delta_j^{[l]} = \frac{\partial C}{\partial z_j^{[l]}}, \quad \forall j, \quad 2 \leq l \leq L,$$

Serão úteis. Note que

$$z_j^{[l]} = W^{[l]} a^{[l-1]} + b^{[l]}, \quad 2 \leq l \leq L,$$

foram calculados no feed forward, assim como  
 $a^{[l]}$ ,  $1 \leq l \leq L$ .



- $a^{[L]} = a(z_j^{[L]}) \Rightarrow \frac{\partial a_j^{[L]}}{\partial z_j^{[L]}} = a'(z_j^{[L]})$

(17)

- $\frac{\partial C}{\partial a_j^{[L]}} = \frac{\partial}{\partial a_j^{[L]}} \frac{1}{2} \|a^{[L]} - y\|^2 = a_j^{[L]} - y_j$

- $\odot \delta_j^{[L]} = \frac{\partial C}{\partial z_j^{[L]}} = \frac{\partial C}{\partial a_j^{[L]}} \cdot \frac{a_j^{[L]}}{\partial z_j^{[L]}} = (a_j^{[L]} - y_j) a'(z_j^{[L]})$

Agora tratamos os  $\delta^{[l]}$  intermediários ( $l < L$ ).  
A ideia é escrever  $\delta^{[l]}$  em função de  $\delta^{[l+1]}$

(Lembre-se que no back propagation vamos da 118  
camada de saída p/ a de entrada). Para  
relacionar  $\delta_j^{[l]} = \frac{\partial C}{\partial z_j^{[l]}}$  a  $\delta_k^{[l+1]} = \frac{\partial C}{\partial z_k^{[l+1]}}$ ,

utilizamos novamente a regra da cadeia:

$$\delta_j^{[l]} = \frac{\partial C}{\partial z_j^{[l]}} = \sum_k \frac{\partial C}{\partial z_k^{[l+1]}} \cdot \frac{\partial z_k^{[l+1]}}{\partial z_j^{[l]}} = \sum_k \delta_k^{[l+1]} \frac{\partial z_k^{[l+1]}}{\partial z_j^{[l]}}$$

Como  $z_k^{[l+1]} = w_k^{[l+1]} a_j^{[l]} + b_k^{[l+1]} = \sum_p w_{kp}^{[l+1]} a_p^{[l]} + b_k^{[l+1]}$ ,

temos  $\frac{\partial z_k^{[l+1]}}{\partial z_j^{[l]}} = w_{kj}^{[l+1]} a'(z_j^{[l]})$ . Assim

$$\odot \quad \delta_j^{[l]} = \sum_k \delta_k^{[l+1]} w_{kj}^{[l+1]} a'(z_j^{[l]})$$

$$\Rightarrow \delta_j^{[l]} = a'(z_j^{[l]}) \left( (w^{[l+1]})^T \delta^{[l+1]} \right)_j$$

Finalmente calculamos  $\frac{\partial \mathcal{L}}{\partial w_{jk}^{[l]}}$  e  $\frac{\partial \mathcal{L}}{\partial b_j^{[l]}}$ :

201

- $z_j^{[l]} = (w^{[l]} a^{[l-1]} + b^{[l]})_j = (w^{[l]} a(z^{[l-1]}) + b^{[l]})_j$

$$\Rightarrow \frac{\partial z_j^{[l]}}{\partial b_j^{[l]}} = 1$$

$$\odot \frac{\partial C}{\partial b_j^{[l]}} = \frac{\partial C}{\partial z_j^{[l]}} \cdot \frac{\partial z_j^{[l]}}{\partial b_j^{[l]}} = \delta_j^{[l]}$$

---

- $z_j^{[l]} = (w^{[l]} a^{[l-1]} + b^{[l]})_j = \sum_k w_{jk}^{[l]} a_k^{[l-1]} + b_j^{[l]}$

$$\Rightarrow \frac{\partial z_j^{[l]}}{\partial w_{jk}^{[l]}} = a_k^{[l-1]} \quad \text{Analisando a expres-} \quad (21)$$

são de  $z_p^{[l]}$ ,  $p \neq j$ , vemos que  $w_{jk}^{[l]}$  não

aparece na soma  $\sum_k w_{pk}^{[l]}$ , e logo  $\frac{\partial z_p^{[l]}}{\partial w_{jk}^{[l]}} = 0$ .

Dai,

$$\odot \frac{\partial C}{\partial w_{jk}^{[l]}} = \sum_p \frac{\partial C}{\partial z_p^{[l]}} \cdot \frac{\partial z_p^{[l]}}{\partial w_{jk}^{[l]}} = \frac{\partial C}{\partial z_j^{[l]}} \cdot \frac{\partial z_j^{[l]}}{\partial w_{jk}^{[l]}} = \delta_j^{[l]} a_k^{[l-1]}$$

Resumindo (itens ①) o cálculo de  $C'$ : [22]

$$1) \delta_j^{[L]} = (a_j^{[L]} - y_j) a'(z_j^{[L]}), \quad \forall j \text{ camada saída.}$$

$$2) \delta_j^{[l]} = a'(z_j^{[l]}) \left( (w^{[l+1]})^T \delta^{[l+1]} \right)_j, \quad \forall j, \quad 2 \leq l \leq L-1$$

$$3) \frac{\partial C}{\partial b_j^{[l]}} = \delta_j^{[l]}, \quad \forall j, \quad 2 \leq l \leq L$$

$$4) \frac{\partial C}{\partial w_{jk}^{[l]}} = \delta_j^{[l]} a_k^{[l-1]}, \quad \forall j, k, \quad 2 \leq l \leq L.$$

## Observações:


(23)

- (i) somente 1) depende da escolha de  $C$ .  
Logo, é possível adaptar facilmente este  
back propagation para outras funções  $R_m(u, b)$ .
- 
- (ii) as contas independem da escolha da função  
de ativação  $a$  (basta ser diferenciável nos  
valores avaliados). A derivada  $a'$  deve ser  
fornecido. Por exemplo,  $a(z) = 1/(1 + e^{-z})$   
 $\Rightarrow a'(z) = a(z)(1 - a(z))$ .

Exemplo: considere o exemplo anterior:  $R_2(w, b)$ , (24)  
 $(x_1, y_1) = (1, 1)$ ,  $(x_2, y_2) = (2, 0)$ ,

$$W^{[2]} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad W^{[3]} = \begin{bmatrix} 2 & 3 \end{bmatrix}, \quad b^{[2]} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}, \quad b^{[3]} = [1],$$

sigmoid  $a(z) = 1/(1 + e^{-z})$  em todos os neurônios.



Vamos calcular  $\nabla \left\{ \frac{1}{2} \|a^{[L]} - y\|^2 \right\}$  para o dado 1 no



ponto  $(w, b)$  fornecido.

---

25

Se aplicarmos feed forward, encontramos

- $a^{[1]} = [1]$

- $a^{[2]} = \begin{bmatrix} 0,5 \\ -0,1398 \end{bmatrix}$  ,  $z^{[2]} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$

- $a^{[3]} = [-0,3033]$  ,  $z^{[3]} = [1,5807]$

(reveja as contas do exemplo anterior).

$$1) \delta^{[3]} = (a_1^{[3]} - y_1) a'(z_1^{[3]}) \approx (-1,3033) [a^{[3]}(1-a^{[3]})]^{26} \\ \approx [0,5152]$$


---

$$2) (w^{[3]})^T \delta^{[3]} \approx \begin{bmatrix} 2 \\ 3 \end{bmatrix} [0,5152] = \begin{bmatrix} 1,0304 \\ 1,5456 \end{bmatrix}$$

$$\delta^{[2]} \approx \begin{bmatrix} a'(z_1^{[2]}) (1,0304) \\ a'(z_2^{[2]}) (1,5456) \end{bmatrix} = \begin{bmatrix} 1,0304 \cdot a_1^{[2]} (1 - a_1^{[2]}) \\ 1,5456 \cdot a_2^{[2]} (1 - a_2^{[2]}) \end{bmatrix}$$

$$\approx \begin{bmatrix} 0,2576 \\ -0,2463 \end{bmatrix}$$

$$3) \frac{\partial C}{\partial b_1^{[2]}} = \delta_1^{[2]} = 0,2576$$

$$\frac{\partial C}{\partial b_2^{[2]}} = \delta_2^{[2]} = -0,2463$$

$$\frac{\partial C}{\partial b_1^{[3]}} = \delta_1^{[3]} = 0,5152$$

$$\nabla_b C(w, b).$$

4) Faça as contas e calcule  $\nabla_w C(w, b)$ .