

Comparação de desempenho entre algoritmos

Leonardo D. Secchin

Tópicos em PO, 2021/1E

UFES

Julho de 2021

Considere dois algoritmos A e B aplicados aos problemas P_1, \dots, P_n . Após a execução, o seguinte panorama foi observado:

- o Algoritmo A resolveu 65% dos problemas
- o Algoritmo B resolveu 72% dos problemas
- o tempo de execução do Algoritmo B foi, em média, 2 vezes o tempo do Algoritmo A.

Considere dois algoritmos A e B aplicados aos problemas P_1, \dots, P_n . Após a execução, o seguinte panorama foi observado:

- o Algoritmo A resolveu 65% dos problemas
- o Algoritmo B resolveu 72% dos problemas
- o tempo de execução do Algoritmo B foi, em média, 2 vezes o tempo do Algoritmo A.

Pergunta: Qual algoritmo foi melhor? Qual você indicaria?

Considere dois algoritmos A e B aplicados aos problemas P_1, \dots, P_n . Após a execução, o seguinte panorama foi observado:

- o Algoritmo A resolveu 65% dos problemas
- o Algoritmo B resolveu 72% dos problemas
- o tempo de execução do Algoritmo B foi, em média, 2 vezes o tempo do Algoritmo A.

Pergunta: Qual algoritmo foi melhor? Qual você indicaria?

A resposta possivelmente dependa da situação, do tamanho dos problemas, do condicionamento dos dados, de paralelismo etc etc etc...

Considere dois algoritmos A e B aplicados aos problemas P_1, \dots, P_n . Após a execução, o seguinte panorama foi observado:

- o Algoritmo A resolveu 65% dos problemas
- o Algoritmo B resolveu 72% dos problemas
- o tempo de execução do Algoritmo B foi, em média, 2 vezes o tempo do Algoritmo A.

Pergunta: Qual algoritmo foi melhor? Qual você indicaria?

A resposta possivelmente dependa da situação, do tamanho dos problemas, do condicionamento dos dados, de paralelismo etc etc etc...

ok, mas há uma forma de responder “balanceando” tempo vs eficácia?

Agora, tente dar uma “resposta média” olhando a tabela... !!!!! :(

Row	Prob	n	m	st	it	f	viab	KKT	tempo	metodo
1	lp_adlittle	138	56	1	8	NaN	4.59223e12	5.6862e8	0.00625257	afimescala
2	lp_adlittle	138	56	0	13	225495.0	1.38656e-10	2.17674e-10	0.00219731	pred-corr_p2
3	lp_adlittle	138	56	0	13	225495.0	1.38062e-9	4.6669e-12	0.00212062	pred-corr_p3
4	lp_adlittle	138	56	1	20	NaN	1.24738e-10	2.84205e-8	0.00350535	seguidor
5	lp_afiro	51	27	4	18	-464.754	10.071	0.00554879	0.00123545	afimescala
6	lp_afiro	51	27	0	8	-464.753	6.56722e-12	7.32249e-10	0.000450609	pred-corr_p2
7	lp_afiro	51	27	0	8	-464.753	9.48886e-12	1.60566e-10	0.000536535	pred-corr_p3
8	lp_afiro	51	27	0	16	-464.753	5.10003e-12	2.49791e-9	0.000865001	seguidor
9	lp_agg	615	488	1	33	NaN	3.52612e15	6.39858e7	0.0930459	afimescala
10	lp_agg	615	488	0	27	-3.59918e7	2.7054e-5	1.92828e-9	0.0961403	pred-corr_p2
11	lp_agg	615	488	0	39	-3.59918e7	1.0664e-5	6.31478e-13	0.142016	pred-corr_p3
12	lp_agg	615	488	0	57	-3.59918e7	0.0658189	1.56728e-9	0.143155	seguidor
13	lp_agg2	758	516	4	61	-1.99724e7	137955.0	0.00798686	0.203749	afimescala
14	lp_agg2	758	516	0	20	-2.02393e7	2.11389e-7	7.04435e-12	0.0931601	pred-corr_p2
15	lp_agg2	758	516	0	19	-2.02393e7	2.02984e-5	1.72002e-10	0.0913567	pred-corr_p3
16	lp_agg2	758	516	0	30	-2.02393e7	0.00172784	6.43798e-9	0.0974315	seguidor
17	lp_agg3	758	516	1	50	NaN	5.01421e15	2.92043e8	0.163052	afimescala
18	lp_agg3	758	516	0	20	1.03121e7	3.48558e-7	1.30753e-9	0.0950648	pred-corr_p2
19	lp_agg3	758	516	0	18	1.03121e7	9.58804e-6	9.13078e-11	0.0866596	pred-corr_p3
20	lp_agg3	758	516	0	32	1.03121e7	0.000617788	1.45328e-9	0.109657	seguidor
21	lp_bandm	472	305	4	16	-139.181	25.8847	0.370008	0.0234934	afimescala
22	lp_bandm	472	305	0	19	-158.628	6.21731e-10	5.5994e-9	0.0289009	pred-corr_p2
23	lp_bandm	472	305	0	19	-158.628	3.3434e-10	1.92558e-12	0.0266341	pred-corr_p3
24	lp_bandm	472	305	0	31	-158.628	3.01558e-10	6.49026e-9	0.0348959	seguidor
25	lp_beaconfd	295	173	4	16	33574.4	3230.33	0.219422	0.0131723	afimescala
26	lp_beaconfd	295	173	0	11	33592.5	1.33872e-5	6.59554e-9	0.0102533	pred-corr_p2
27	lp_beaconfd	295	173	0	10	33592.5	1.61167e-8	6.77704e-12	0.00898379	pred-corr_p3
28	lp_beaconfd	295	173	0	18	33592.5	2.93402e-9	4.69255e-9	0.0125896	seguidor
29	lp_blend	114	74	4	20	-29.8934	7.46157	0.0660842	0.00431388	afimescala
30	lp_blend	114	74	0	14	-30.8121	1.47306e-11	9.00176e-10	0.00327916	pred-corr_p2
31	lp_blend	114	74	0	13	-30.8121	3.29287e-11	1.70695e-11	0.00308425	pred-corr_p3
32	lp_blend	114	74	0	20	-30.8121	2.25261e-11	9.91278e-9	0.00369068	seguidor
33	lp_bn12	4486	2324	1	45	NaN	1.10967e15	3.02111e10	1.10452	afimescala
34	lp_bn12	4486	2324	4	40	1811.24	0.00125769	3.42411e-8	1.74602	pred-corr_p2
35	lp_bn12	4486	2324	4	36	1811.24	0.000585816	1.59491e-8	1.58145	pred-corr_p3
36	lp_bn12	4486	2324	0	68	1811.24	5.68037e-7	6.48521e-10	1.65283	seguidor
37	lp_d2q06c	5831	2171	4	13	2.52971e5	2.17288e5	1.49644	0.412703	afimescala
38	lp_d2q06c	5831	2171	4	26	1.22829e5	8.90209e-5	0.000328237	1.29015	pred-corr_p2
39	lp_d2q06c	5831	2171	0	30	1.22784e5	3.41739e-5	2.07375e-9	1.47965	pred-corr_p3
40	lp_d2q06c	5831	2171	0	62	1.22784e5	1.17896e-5	1.63516e-9	1.80164	seguidor

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

- **Tempo de execução:** útil para comparar algoritmos de diferentes naturezas. *Veremos mais a frente alguns cuidados ao contabilizar tempo de CPU.*

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

- **Tempo de execução:** útil para comparar algoritmos de diferentes naturezas. *Veremos mais a frente alguns cuidados ao contabilizar tempo de CPU.*
- **Número de iterações:** útil quando os algoritmos têm iterações com custo computacional parecido.

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

- **Tempo de execução:** útil para comparar algoritmos de diferentes naturezas. *Veremos mais a frente alguns cuidados ao contabilizar tempo de CPU.*
- **Número de iterações:** útil quando os algoritmos têm iterações com custo computacional parecido. Exemplos:
 - Pontos interiores primal dual afim escala, seguidor de caminhos e preditor-corretor – custo por iteração parecido

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

- **Tempo de execução:** útil para comparar algoritmos de diferentes naturezas. *Veremos mais a frente alguns cuidados ao contabilizar tempo de CPU.*
- **Número de iterações:** útil quando os algoritmos têm iterações com custo computacional parecido. Exemplos:
 - Pontos interiores primal dual afim escala, seguidor de caminhos e preditor-corretor – custo por iteração parecido
 - Método do gradiente e Newton – custo por iteração muito diferente. O primeiro necessita apenas de ∇f ; o segundo, resolver um sistema linear com $\nabla^2 f$.
 \implies Não faz sentido comparar por número de iterações (gradiente pode dar mais iterações e mesmo assim ser muito mais rápido)

Algoritmos podem ser comparados por diversas medidas.

A medida de comparação deve ser positiva e “menor \implies melhor”.

- **Tempo de execução:** útil para comparar algoritmos de diferentes naturezas. *Veremos mais a frente alguns cuidados ao contabilizar tempo de CPU.*
- **Número de iterações:** útil quando os algoritmos têm iterações com custo computacional parecido. Exemplos:
 - Pontos interiores primal dual afim escala, seguidor de caminhos e preditor-corretor – custo por iteração parecido
 - Método do gradiente e Newton – custo por iteração muito diferente. O primeiro necessita apenas de ∇f ; o segundo, resolver um sistema linear com $\nabla^2 f$.
 \implies Não faz sentido comparar por número de iterações (gradiente pode dar mais iterações e mesmo assim ser muito mais rápido)
- **Número de avaliações de funções e/ou gradientes:** útil quando é caro avaliar funções e seus gradientes – problemas de grande porte, funções resultantes de processos iterativos

Independentemente da medida de comparação, queremos uma forma fácil de comparar o desempenho entre dois ou mais algoritmos.

Independentemente da medida de comparação, queremos uma forma fácil de comparar o desempenho entre dois ou mais algoritmos.

Como?

Perfis de desempenho: uma forma visual de comparação

Independentemente da medida de comparação, queremos uma forma fácil de comparar o desempenho entre dois ou mais algoritmos.

Como?

Perfis de desempenho: uma forma visual de comparação

Os perfis de desempenho que veremos foram idealizados por Elizabeth D. Dolan e Jorge J. Moré.

Dolan, Elizabeth D.; Moré, Jorge J. Benchmarking optimization software with performance profiles. Math. Program., Ser. A 91: 201-213 (2002)

Eles são muito utilizados pelos pesquisadores em otimização.

Construção dos perfis de desempenho

Vamos fixar **tempo de execução** como medida (as outras são análogas).

Construção dos perfis de desempenho

Vamos fixar **tempo de execução** como medida (as outras são análogas).

Sejam

- \mathcal{P} o conjunto dos problemas-teste (instâncias);
- \mathcal{A} o conjunto dos algoritmos aplicados à cada problema $p \in \mathcal{P}$;
- $t_{p,a}$ o tempo de execução do algoritmo $a \in \mathcal{A}$ para resolver $p \in \mathcal{P}$.

Definimos $t_{p,a} = \infty$ caso a **não** resolveu p .

O tempo será em segundos, mas isso não importa para comparar...

Construção dos perfis de desempenho

O **índice de desempenho** do algoritmo a no problema p é a razão

$$r_{p,a} = \frac{t_{p,a}}{\min\{t_{p,\tilde{a}} \mid \tilde{a} \in \mathcal{A}\}} \geq 1$$

- $r_{p,a} = \tau$ significa que a levou τ vezes o tempo do algoritmo mais rápido em p .

Por exemplo, $r_{p,a} = 2 \implies a$ levou o **dobro** do tempo do algoritmo mais rápido em p .

Construção dos perfis de desempenho

O **índice de desempenho** do algoritmo a no problema p é a razão

$$r_{p,a} = \frac{t_{p,a}}{\min\{t_{p,\tilde{a}} \mid \tilde{a} \in \mathcal{A}\}} \geq 1$$

- $r_{p,a} = \tau$ significa que a levou τ vezes o tempo do algoritmo mais rápido em p .

Por exemplo, $r_{p,a} = 2 \implies a$ levou o **dobro** do tempo do algoritmo mais rápido em p .

- $r_{p,a} = 1 \implies$ algoritmo a resolveu p mais rápido;

Construção dos perfis de desempenho

O **índice de desempenho** do algoritmo a no problema p é a razão

$$r_{p,a} = \frac{t_{p,a}}{\min\{t_{p,\tilde{a}} \mid \tilde{a} \in \mathcal{A}\}} \geq 1$$

- $r_{p,a} = \tau$ significa que a levou τ vezes o tempo do algoritmo mais rápido em p .

Por exemplo, $r_{p,a} = 2 \implies a$ levou o **dobro** do tempo do algoritmo mais rápido em p .

- $r_{p,a} = 1 \implies$ algoritmo a resolveu p mais rápido;
- quanto maior $r_{p,a}$, mais lento foi a em p (talvez nem resolveu)

Construção dos perfis de desempenho

O **índice de desempenho** do algoritmo a no problema p é a razão

$$r_{p,a} = \frac{t_{p,a}}{\min\{t_{p,\tilde{a}} \mid \tilde{a} \in \mathcal{A}\}} \geq 1$$

- $r_{p,a} = \tau$ significa que a levou τ vezes o tempo do algoritmo mais rápido em p .

Por exemplo, $r_{p,a} = 2 \implies a$ levou o **dobro** do tempo do algoritmo mais rápido em p .

- $r_{p,a} = 1 \implies$ algoritmo a resolveu p mais rápido;
- quanto maior $r_{p,a}$, mais lento foi a em p (talvez nem resolveu)
- convencionamos $r_{p,a} = \infty$ caso $t_{p,a} = \infty$ (note que o denominador pode ser ∞ caso nenhum algoritmo tenha resolvido p).

Construção dos perfis de desempenho

Definimos o **perfil de desempenho** (ou **função de desempenho**) do algoritmo $a \in \mathcal{A}$ por

$$\rho_a : [1, \infty) \rightarrow [0, 1], \quad \rho_a(\tau) = \frac{1}{\#\mathcal{P}} \text{card} \{p \in \mathcal{P} \mid r_{p,a} \leq \tau\}.$$

- $\rho_a(1)$ é a proporção de problemas em que a foi o **mais rápido**;
- $\rho_a(\tau)$ é a proporção de problemas que a resolve **em até τ vezes** o tempo do algoritmo mais rápido.

Construção dos perfis de desempenho

Definimos o **perfil de desempenho** (ou **função de desempenho**) do algoritmo $a \in \mathcal{A}$ por

$$\rho_a : [1, \infty) \rightarrow [0, 1], \quad \rho_a(\tau) = \frac{1}{\#\mathcal{P}} \text{card} \{p \in \mathcal{P} \mid r_{p,a} \leq \tau\}.$$

- $\rho_a(1)$ é a proporção de problemas em que a foi o **mais rápido**;
- $\rho_a(\tau)$ é a proporção de problemas que a resolve **em até τ vezes** o tempo do algoritmo mais rápido.
- a função ρ_a balanceia **tempo** e **eficácia**.
 - qual o algoritmo mais rápido, desconsiderando eficácia?
 - qual o algoritmo é mais rápido, considerando uma taxa mínima de 70% dos problemas resolvidos?

Construção dos perfis de desempenho

A maneira fácil de visualizar o comparativo entre algoritmos é traçando os gráficos de $\rho_a(\tau)$ em função de τ , para os vários algoritmos.

É bastante utilizada pelos pesquisadores para tirar conclusões entre diferentes algoritmos.

Construção dos perfis de desempenho

A maneira fácil de visualizar o comparativo entre algoritmos é traçando os gráficos de $\rho_a(\tau)$ em função de τ , para os vários algoritmos.


É bastante utilizada pelos pesquisadores para tirar conclusões entre diferentes algoritmos.

Os perfis ρ_a podem ser definidos para qualquer medida de comparação (iterações, avaliações de função etc) de forma inteiramente análoga.

→ Para tanto, basta definir $t_{p,a}$ como a medida de interesse, mantendo $t_{p,a} = \infty$ quando a não resolve p .

Exemplo 1

**Comparativo para até 10 vezes o tempo
do algoritmo mais rápido ($\tau \in [1, 10]$)**




(figura adaptada do artigo de Dolan e Moré (2002))

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)

LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz




(figura adaptada do artigo de Dolan e Moré (2002))

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)

LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz


MINOS é o mais eficaz se esperamos até 10x o tempo do alg. mais rápido



(figura adaptada do artigo de Dolan e Moré (2002))

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)



(figura adaptada do artigo de Dolan e Moré (2002))


LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz

MINOS é o mais eficaz se esperamos até 10x o tempo do alg. mais rápido

LOQO e SNOPT têm eficácia similar, porém LOQO é muito mais rápido

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)



(figura adaptada do artigo de Dolan e Moré (2002))

LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz


MINOS é o mais eficaz se esperarmos até 10x o tempo do alg. mais rápido

LOQO e SNOPT têm eficácia similar, porém LOQO é muito mais rápido

A eficácia entre LOQO e SNOPT se equiparam somente se esperarmos até 8,5x o tempo do alg. mais rápido

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)



(figura adaptada do artigo de Dolan e Moré (2002))

LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz

MINOS é o mais eficaz se esperarmos até 10x o tempo do alg. mais rápido


LOQO e SNOPT têm eficácia similar, porém LOQO é muito mais rápido

A eficácia entre LOQO e SNOPT se equiparam somente se esperarmos até 8,5x o tempo do alg. mais rápido

MINOS tem eficácia superior se esperarmos até cerca de 4x do algoritmo mais rápido

Exemplo 1

Comparativo para até 10 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 10]$)



(figura adaptada do artigo de Dolan e Moré (2002))

LOQO é mais rápido em $\approx 60\%$ dos problemas, mas não é o mais eficaz

MINOS é o mais eficaz se esperamos até 10x o tempo do alg. mais rápido

LOQO e SNOPT têm eficácia similar, porém LOQO é muito mais rápido


A eficácia entre LOQO e SNOPT se equiparam somente se esperarmos até 8,5x o tempo do alg. mais rápido

MINOS tem eficácia superior se esperarmos até cerca de 4x do algoritmo mais rápido

LANCELOT é pior em eficácia e tempo

Exemplo 2


**Comparativo para até 100 vezes o tempo
do algoritmo mais rápido ($\tau \in [1, 100]$)**



(figura adaptada do artigo de Dolan e Moré (2002))

Exemplo 2

Comparativo para até 100 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 100]$)




SNOPT é o mais eficaz, porém para resolver $\approx 90\%$ dos problemas devemos esperar mais de 40x o tempo do algoritmo mais rápido

(figura adaptada do artigo de Dolan e Moré (2002))

Exemplo 2

**Comparativo para até 100 vezes o tempo
do algoritmo mais rápido ($\tau \in [1, 100]$)**




(figura adaptada do artigo de Dolan e Moré (2002))

SNOPT é o mais eficaz, porém para resolver $\approx 90\%$ dos problemas devemos esperar mais de 40x o tempo do algoritmo mais rápido

LANCELOT aumenta sua eficácia se esperamos mais tempo

Exemplo 2

Comparativo para até 100 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 100]$)



(figura adaptada do artigo de Dolan e Moré (2002))


SNOPT é o mais eficaz, porém para resolver $\approx 90\%$ dos problemas devemos esperar mais de 40x o tempo do algoritmo mais rápido

LANCELOT aumenta sua eficácia se esperamos mais tempo

LOQO resolve apenas poucos problemas a mais para $\tau \geq 50$

Exemplo 2

Comparativo para até 100 vezes o tempo do algoritmo mais rápido ($\tau \in [1, 100]$)



(figura adaptada do artigo de Dolan e Moré (2002))

SNOPT é o mais eficaz, porém para resolver $\approx 90\%$ dos problemas devemos esperar mais de 40x o tempo do algoritmo mais rápido

LANCELOT aumenta sua eficácia se esperamos mais tempo


LOQO resolve apenas poucos problemas a mais para $\tau \geq 50$

MINOS não é mais eficaz se esperamos mais tempo

Exemplo 3

Como perfis de dois algoritmos podem se cruzar?

	A1	A2	r_1	r_2
P1	10	20	1,00	2,00
P2	3	7	1,00	2,33
P3	6	8	1,00	1,33
P4	12	13	1,00	1,08
P5	∞	50	∞	1,00
$\rho(1)$	0,8	0,2		
$\rho(2)$	0,8	0,6		
$\rho(3)$	0,8	1,0		



Escala logarítmica

As vezes o gráfico fica ilegível próximo de $\tau = 1$. Podemos usar uma escala logarítmica de base 2 (proposto por Dolan e Moré) no eixo τ para melhor visualização.

Na verdade, a proposta é plotar



$$\rho_a : [1, \infty) \rightarrow [0, 1], \quad \rho_a(\tau) = \frac{1}{\#\mathcal{P}} \text{card} \{p \in \mathcal{P} \mid \log_2(r_{p,a}) \leq \tau\}.$$

A escala logarítmica serve para dar mais ênfase aos valores τ menores.

“estica o eixo” para $\tau \approx 1$ e “comprime o eixo” para $\tau \gg 1$.

Problema: a leitura fica menos intuitiva...

Exemplo



(figuras adaptadas do artigo de Dolan e Moré (2002))

Eixo horizontal: à esquerda, $\tau \geq 1$; à direita, $\log_2(\tau) \geq 0$.

Obs: $\log_2(40) \approx 5,322$, $\log_2(100) \approx 9,966$

O pacote Julia BenchmarkProfiles.jl

O pacote BenchmarkProfiles.jl gera facilmente perfis de desempenho a partir da tabela dos dados.

O pacote Julia BenchmarkProfiles.jl

O pacote BenchmarkProfiles.jl gera facilmente perfis de desempenho a partir da tabela dos dados.

Exercício:

- 1 Gere uma tabela 25×3 fictícia para 3 algoritmos e 25 problemas:

```
julia> T = 10 * rand(25,3);
```

O pacote `BenchmarkProfiles.jl`

O pacote `BenchmarkProfiles.jl` gera facilmente perfis de desempenho a partir da tabela dos dados.

Exercício:

- 1 Gere uma tabela 25×3 fictícia para 3 algoritmos e 25 problemas:

```
julia> T = 10 * rand(25,3);
```

- 2 Insira alguns tempos infinitos nos dados:

```
julia> T[1:7:end] .= Inf;
```

O pacote Julia BenchmarkProfiles.jl

O pacote BenchmarkProfiles.jl gera facilmente perfis de desempenho a partir da tabela dos dados.

Exercício:

- 1 Gere uma tabela 25×3 fictícia para 3 algoritmos e 25 problemas:

```
julia> T = 10 * rand(25,3);
```

- 2 Insira alguns tempos infinitos nos dados:

```
julia> T[1:7:end] .= Inf;
```

- 3 Gere um perfil dos dados T com a legenda “Alg 1”, “Alg 2”, “Alg 3”:

```
julia> fig = performance_profile(ArrayFloat64(T), ["Alg 1", "Alg 2", "Alg 3"], title="Tempo CPU", logscale=false)
```

O pacote Julia BenchmarkProfiles.jl

O pacote BenchmarkProfiles.jl gera facilmente perfis de desempenho a partir da tabela dos dados.

Exercício:

- 1 Gere uma tabela 25×3 fictícia para 3 algoritmos e 25 problemas:

```
julia> T = 10 * rand(25,3);
```

- 2 Insira alguns tempos infinitos nos dados:

```
julia> T[1:7:end] .= Inf;
```

- 3 Gere um perfil dos dados T com a legenda “Alg 1”, “Alg 2”, “Alg 3”:

```
julia> fig = performance_profile(ArrayFloat64(T), ["Alg 1", "Alg 2", "Alg 3"], title="Tempo CPU", logscale=false)
```

- 4 Salve a figura em PDF (carregue Plots antes):

```
julia> savefig(fig, "fig.pdf")
```

O pacote Julia BenchmarkProfiles.jl

O pacote BenchmarkProfiles.jl gera facilmente perfis de desempenho a partir da tabela dos dados.

Exercício:

- 1 Gere uma tabela 25×3 fictícia para 3 algoritmos e 25 problemas:

```
julia> T = 10 * rand(25,3);
```

- 2 Insira alguns tempos infinitos nos dados:

```
julia> T[1:7:end] .= Inf;
```

- 3 Gere um perfil dos dados T com a legenda "Alg 1", "Alg 2", "Alg 3":


```
julia> fig = performance_profile(ArrayFloat64(T), ["Alg 1", "Alg 2", "Alg 3"], title="Tempo CPU", logscale=false)
```

- 4 Salve a figura em PDF (carregue Plots antes):

```
julia> savefig(fig, "fig.pdf")
```


- 5 Gere o mesmo perfil com escala logarítmica (padrão) e salve a figura.

Exemplo – pontos interiores (Tempo CPU, “com cautela”)





afimescala é **pior** em tempo e eficácia; *pre-corr_p3* é **melhor** em tempo e eficácia; *seguidor* é **mais lento** que *pre-corr_p3* porém, **se esperamos $\approx 1,9$ vezes o tempo do mais rápido (*pre-corr_p3*), ele é mais eficaz que *pre-corr_p2*.**

Exemplo – pontos interiores (Número de iterações)





As conclusões são parecidas com o perfil de tempo, pois todos os métodos têm iterações com custo similar.

Exemplo – pontos interiores (Tempo CPU)



Eixo horizontal: à esquerda, $\tau \geq 1$; à direita, $\log_2(\tau) \geq 0$.

Exemplo – pontos interiores (Número de iterações)



Eixo horizontal: à esquerda, $\tau \geq 1$; à direita, $\log_2(\tau) \geq 0$.

- Recomendo usar a estrutura *DataFrames* para gerenciar tabelas.
 - Pacote `DataFrames.jl`
 - Similar ao *dataframe* do Python
 - Veja https://leonardosecchin.github.io/juliaopt_ex12

- Recomendo usar a estrutura *DataFrames* para gerenciar tabelas.
 - Pacote `DataFrames.jl`
 - Similar ao *dataframe* do Python
 - Veja https://leonardosecchin.github.io/juliaopt_ex12
- Para evitar erros, sempre converta os dados para `Float64` como no exemplo anterior (esse tipo aceita o “número” `Inf`)

- Recomendo usar a estrutura *DataFrames* para gerenciar tabelas.
 - Pacote `DataFrames.jl`
 - Similar ao *dataframe* do Python
 - Veja https://leonardosecchin.github.io/juliaopt_ex12
- Para evitar erros, sempre converta os dados para `Float64` como no exemplo anterior (esse tipo aceita o “número” `Inf`)
- Salve os resultados em arquivos.
Recomendo arquivos binários pois preservam a estrutura dos objetos.
Veja https://leonardosecchin.github.io/juliaopt_ex11

Dicas no Julia

- Recomendo usar a estrutura *DataFrames* para gerenciar tabelas.
 - Pacote `DataFrames.jl`
 - Similar ao *dataframe* do Python
 - Veja https://leonardosecchin.github.io/juliaopt_ex12
- Para evitar erros, sempre converta os dados para `Float64` como no exemplo anterior (esse tipo aceita o “número” `Inf`)
- Salve os resultados em arquivos.
Recomendo arquivos binários pois preservam a estrutura dos objetos.
Veja https://leonardosecchin.github.io/juliaopt_ex11
- Você pode configurar o perfil de desempenho como uma figura `Plots`.
Veja a seção “*Configurando gráficos*” em https://leonardosecchin.github.io/juliaopt_ex5

Sobre contagem do tempo de execução

A captura do tempo de execução pode sofrer oscilações de processos do sistema, processos concorrentes, paralelismo ou alterações na frequência do processador.

Sobre contagem do tempo de execução

A captura do tempo de execução pode sofrer oscilações de processos do sistema, processos concorrentes, paralelismo ou alterações na frequência do processador.

Dicas para minimizá-las:

- não trabalhe na máquina em que está executando os testes;

Sobre contagem do tempo de execução

A captura do tempo de execução pode sofrer oscilações de processos do sistema, processos concorrentes, paralelismo ou alterações na frequência do processador.

Dicas para minimizá-las:

- não trabalhe na máquina em que está executando os testes;
- fique atento à *swaps*. Eles destroem qualquer contagem de tempo!
Se seu computador não possui memória RAM suficiente, não insista;

Sobre contagem do tempo de execução

A captura do tempo de execução pode sofrer oscilações de processos do sistema, processos concorrentes, paralelismo ou alterações na frequência do processador.

Dicas para minimizá-las:

- não trabalhe na máquina em que está executando os testes;
- fique atento à *swaps*. Eles destroem qualquer contagem de tempo! Se seu computador não possui memória RAM suficiente, não insista;
- se possível, “trave” o processador na sua frequência base, evitando *TurboBoost* ou similares. Talvez requeira acesso como *root* (Linux);

Sobre contagem do tempo de execução

- se sua aplicação não requer paralelismo, pode ser bom executar cada problema com 1 *thread* apenas. Lembre-se que mesmo um programa *serial* pode ter trechos em paralelo pois vários resolvidores de sistemas lineares / pacotes de álgebra linear rodam em paralelo.

Sobre contagem do tempo de execução

- se sua aplicação não requer paralelismo, pode ser bom executar cada problema com 1 *thread* apenas. Lembre-se que mesmo um programa *serial* pode ter trechos em paralelo pois vários resolvedores de sistemas lineares / pacotes de álgebra linear rodam em paralelo.

Geralmente você pode definir o número de *threads* por variáveis de ambiente (Linux). Algumas delas:

- OPENBLAS_NUM_THREADS=1, GOTO_NUM_THREADS=1 : OpenBlas
- OMP_NUM_THREADS=1 : *threads* para códigos com trechos OpenMP
- MKL_NUM_THREADS=1 : Intel© Math Kernel Library© (BLAS da Intel para seus processadores)

Consulte a documentação do *software* que está utilizando.

Sobre contagem do tempo de execução

Inconsistências surgem ainda de oscilações naturais na contagem do tempo (rode um algoritmo várias vezes, você verá que o tempo é diferente a cada execução).

Sobre contagem do tempo de execução

Inconsistências surgem ainda de oscilações naturais na contagem do tempo (rode um algoritmo várias vezes, você verá que o tempo é diferente a cada execução).

- Se seu algoritmo leva “muito” tempo para resolver um problema (p. ex. > 15 seg), então essas oscilações naturais não devem representar grandes variações percentuais...

Sobre contagem do tempo de execução

Inconsistências surgem ainda de oscilações naturais na contagem do tempo (rode um algoritmo várias vezes, você verá que o tempo é diferente a cada execução).

- Se seu algoritmo leva “muito” tempo para resolver um problema (p. ex. > 15 seg), então essas oscilações naturais não devem representar grandes variações percentuais...
- Porém, se seu algoritmo é muito rápido num dado problema (p. ex., < 1 seg), **pequenas oscilações naturais no tempo representam grandes variações percentuais.**

Isso compromete a comparação entre algoritmos em tais problemas.

Como minimizar as variações naturais?

- Utilize sempre as melhores maneiras para contar tempo (aliás, essa dica vale para problemas demorados também).

Por exemplo, no Julia use os comandos `@time` ou `@elapsed`

Veja https://leonardosecchin.github.io/juliaopt_ex14

Como minimizar as variações naturais?

- Utilize sempre as melhores maneiras para contar tempo (aliás, essa dica vale para problemas demorados também).

Por exemplo, no Julia use os comandos `@time` ou `@elapsed`

Veja https://leonardosecchin.github.io/juliaopt_ex14

- Rode cada problema N vezes até somar um tempo “confortável”, por exemplo, 15 seg. O tempo de execução do problema será a média aritmética

$$\frac{\text{tempo total das execuções}}{N}.$$

Isso deve ser implementado!

Isso minimiza **muito** o efeito de oscilações nos problemas pequenos.

Sobre contagem do tempo de execução

Como minimizar as variações naturais?

- Utilize sempre as melhores maneiras para contar tempo (aliás, essa dica vale para problemas demorados também).

Por exemplo, no Julia use os comandos `@time` ou `@elapsed`

Veja https://leonardosecchin.github.io/juliaopt_ex14

- Rode cada problema N vezes até somar um tempo “confortável”, por exemplo, 15 seg. O tempo de execução do problema será a média aritmética

$$\frac{\text{tempo total das execuções}}{N}.$$

Isso deve ser implementado!

Isso minimiza **muito** o efeito de oscilações nos problemas pequenos.

- Você pode simplesmente descartar os problemas cuja execução é muito rápida **caso não sejam relevantes para sua análise.**

Veja

<https://leonardosecchin.github.io/topicospo>